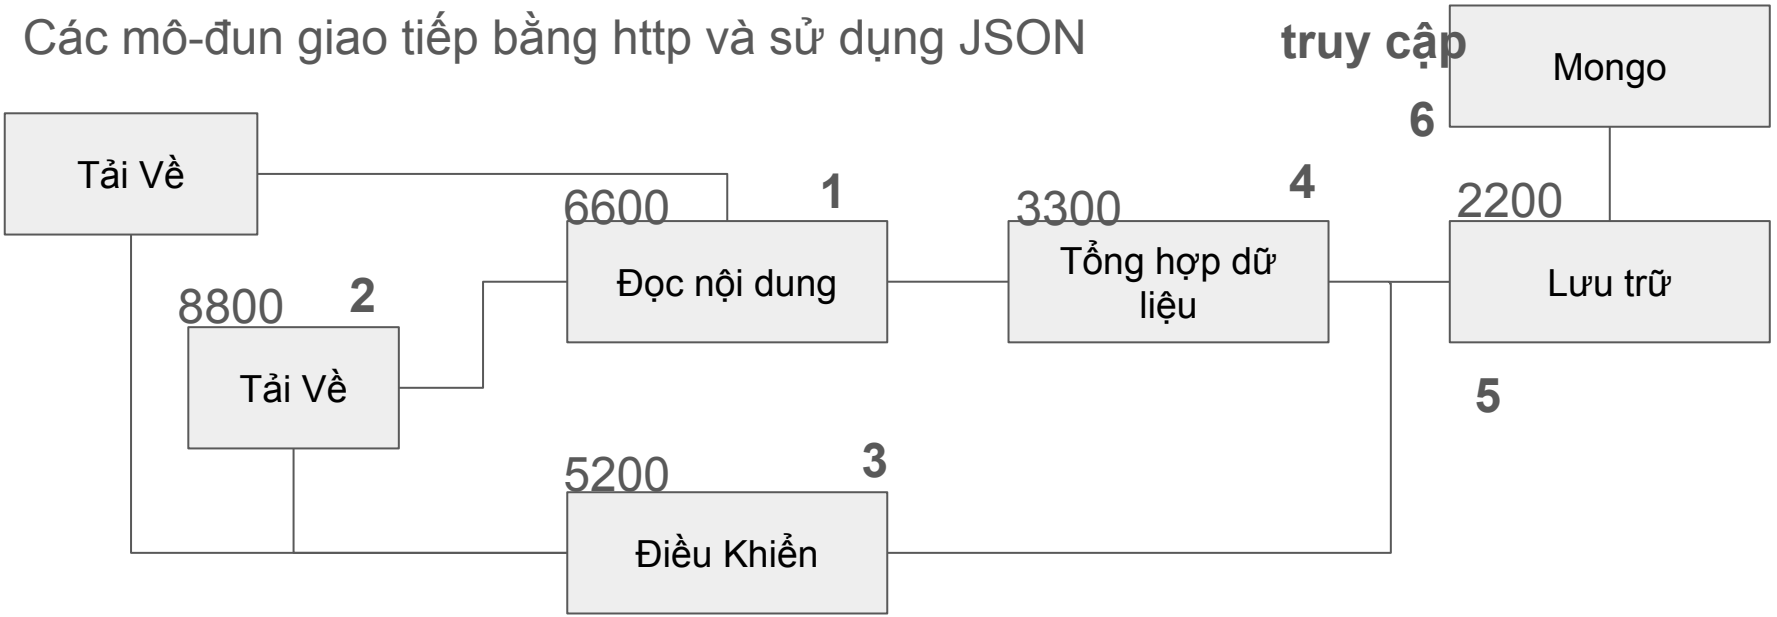
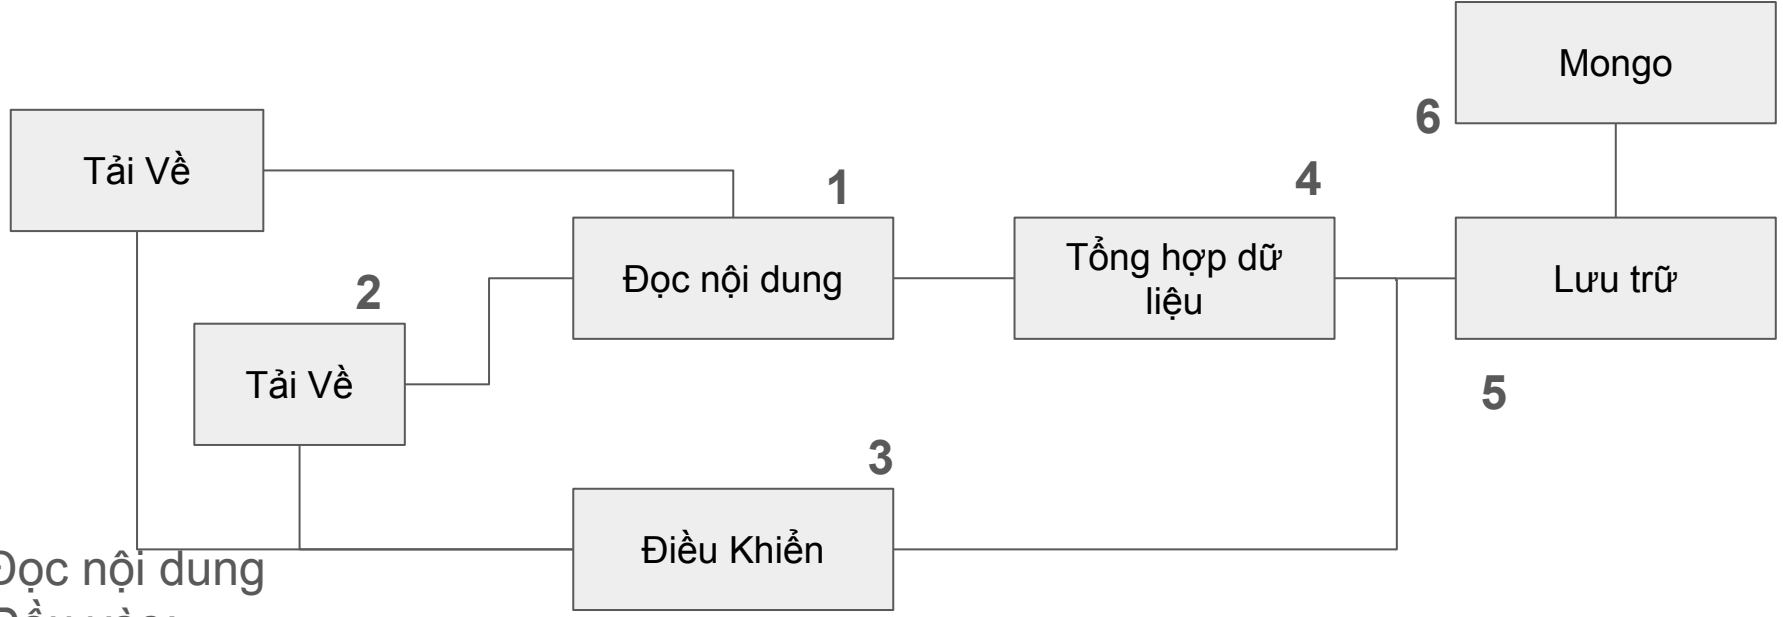
Các mô-đun giao tiếp bằng http và sử dụng JSON



Khởi động - các mô-đun ở trạng thái chờ
Tổng hợp dữ liệu nạp tập url mầm ban đầu.
Mô đun điều khiển gửi url cần thu thập đến Tải về.
Tải về gửi dữ liệu tải được sang đọc nội dung.
Đọc nội dung gửi kết quả bóc tách sang tổng hợp dữ liệu.
Tổng hợp dữ liệu gửi các bản ghi sang lưu trữ
Tổng hợp dữ liệu gửi các url mới sang điều khiển

Đọc nội dung - N1
Tải về - N5
Điều khiển - BAT
Tổng hợp - N8
Lưu trữ - N10
Mongo - Ctrl + F



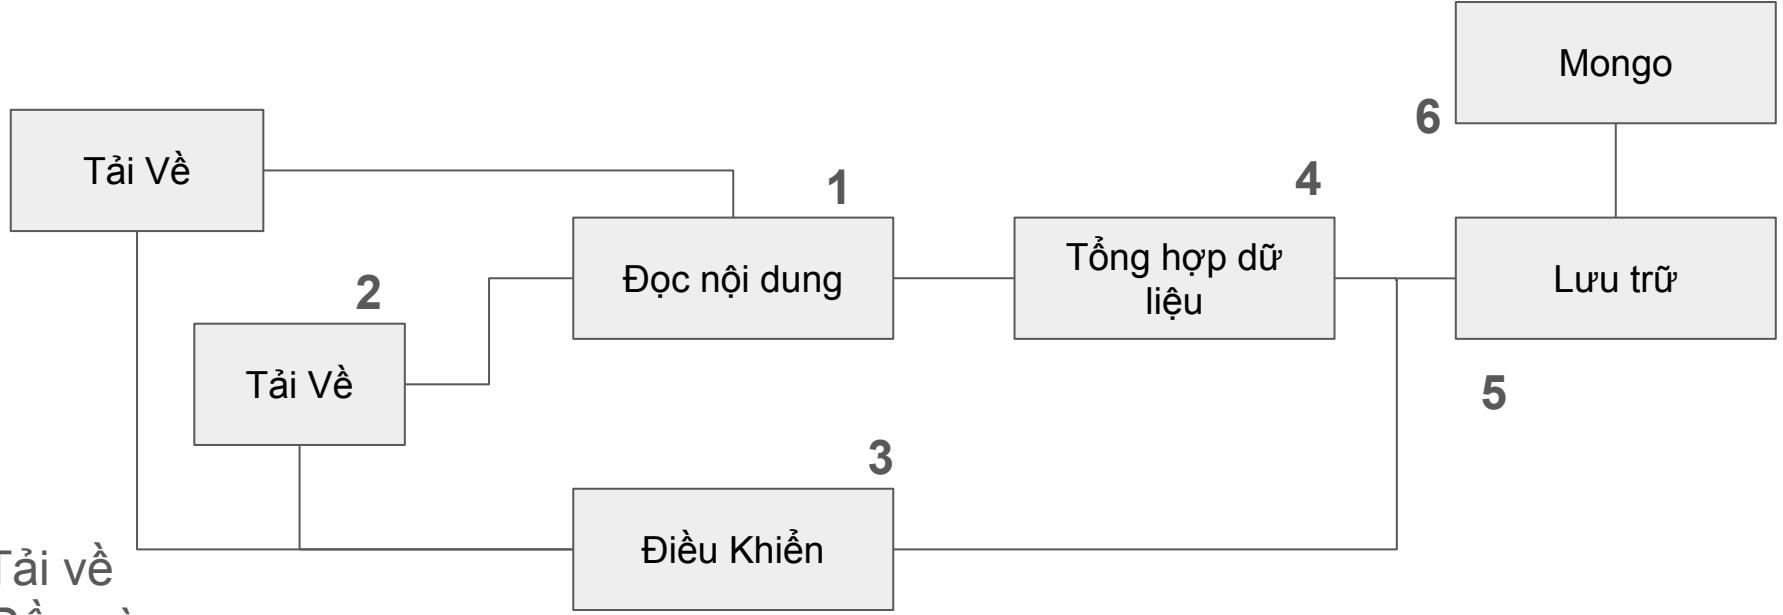
Đọc nội dung

Đầu vào:

- định dạng tài liệu: html, other
- nội dung: tài liệu
- uri: địa chỉ truy cập

Đầu ra:

- *Đối với html: tiêu đề, nội dung văn bản, liên kết đi ra cùng với văn bản liên kết (câu hoàn thiện chứa thẻ a).*
- *Đối với other: Nội dung văn bản tách được*



Tải về

Đầu vào:

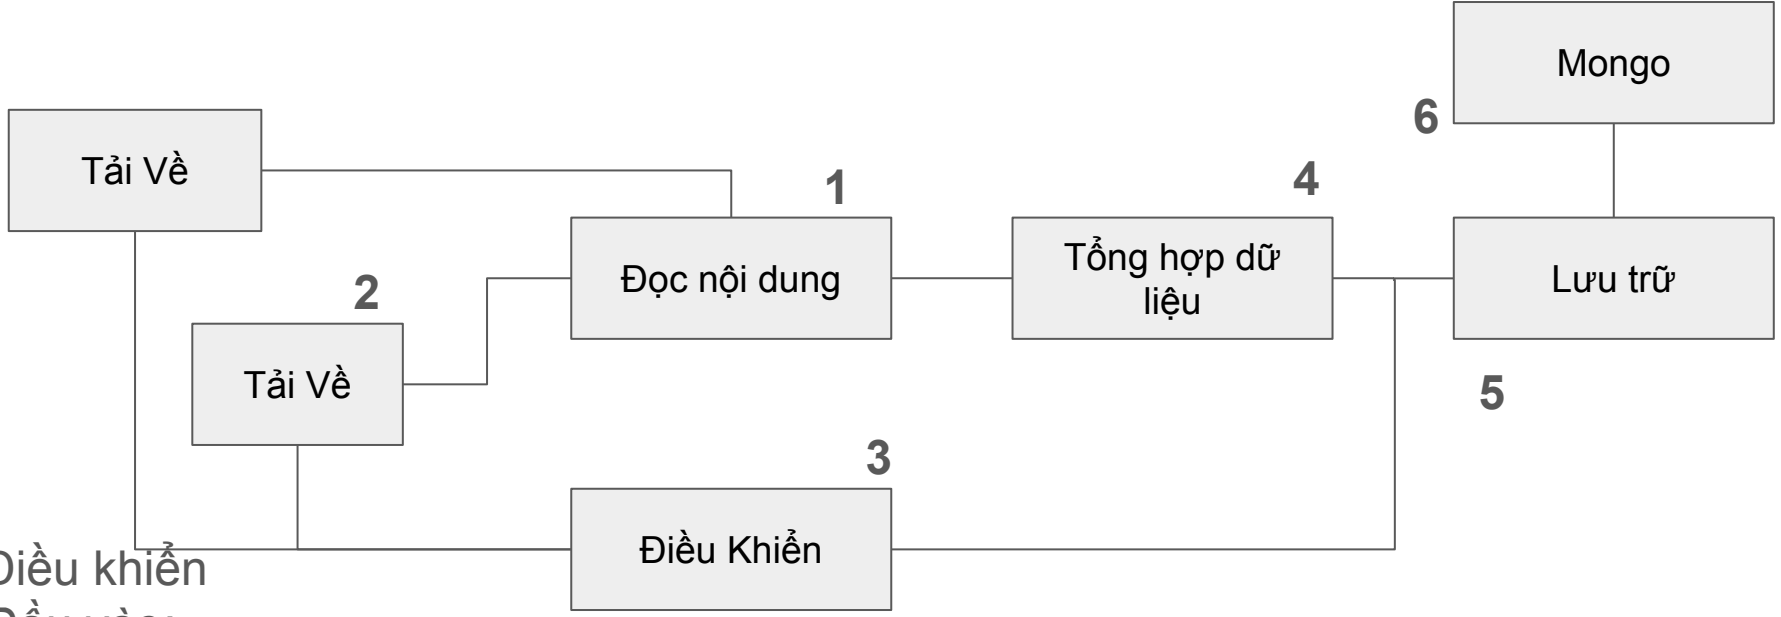
- url: địa chỉ truy cập

Xử lý:

- Pupperteer + Chrome (headless) tải về nội dung đối với trang Web
- Tải tài liệu về đối với tài liệu

Đầu ra:

- *Gửi đến Mô-đun đọc*



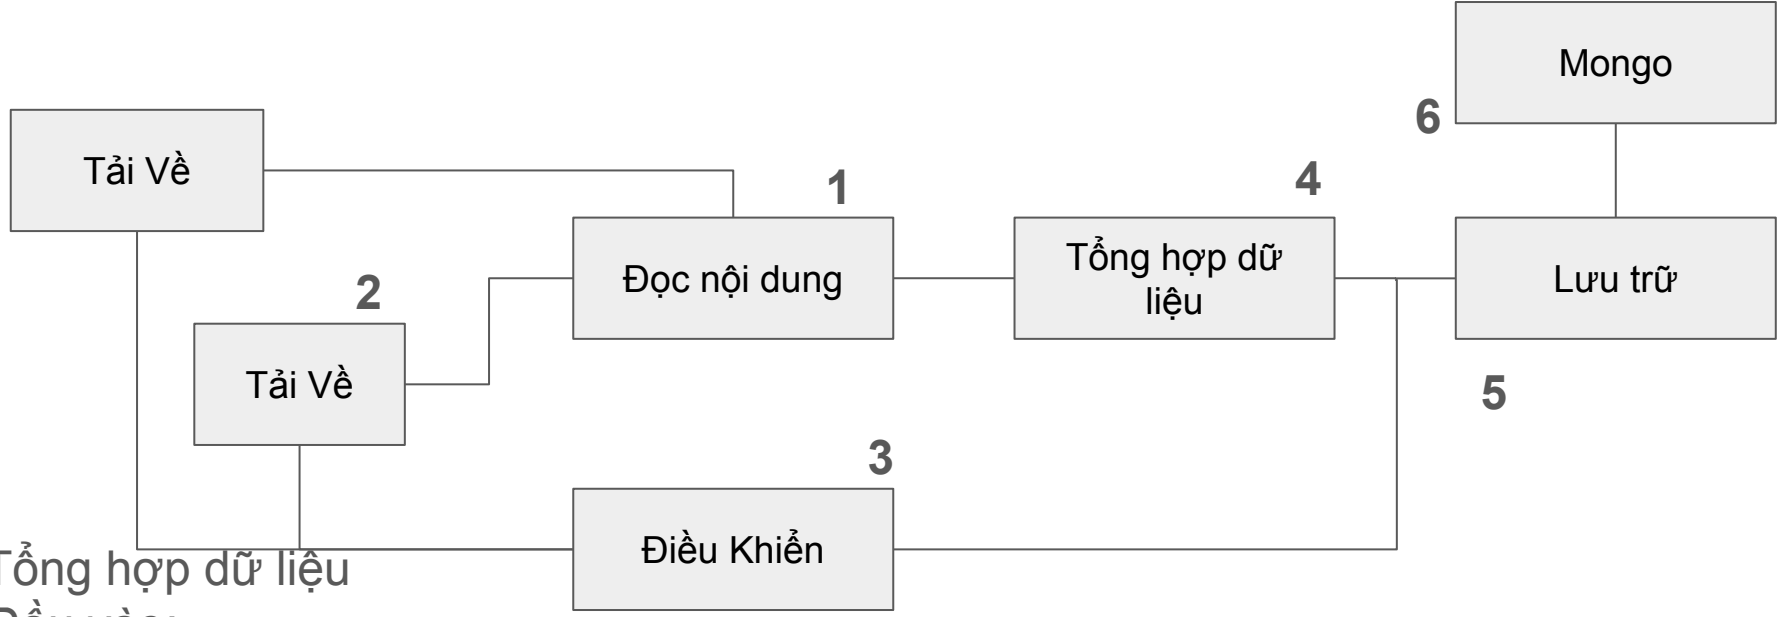
Điều khiển

Đầu vào:

- gói url cần thu thập

Xử lý:

- Thiết lập thời gian chờ và lập lịch gửi đến các mô-đun tải về
- Cân bằng tải - lô-gic xoay vòng.



Tổng hợp dữ liệu

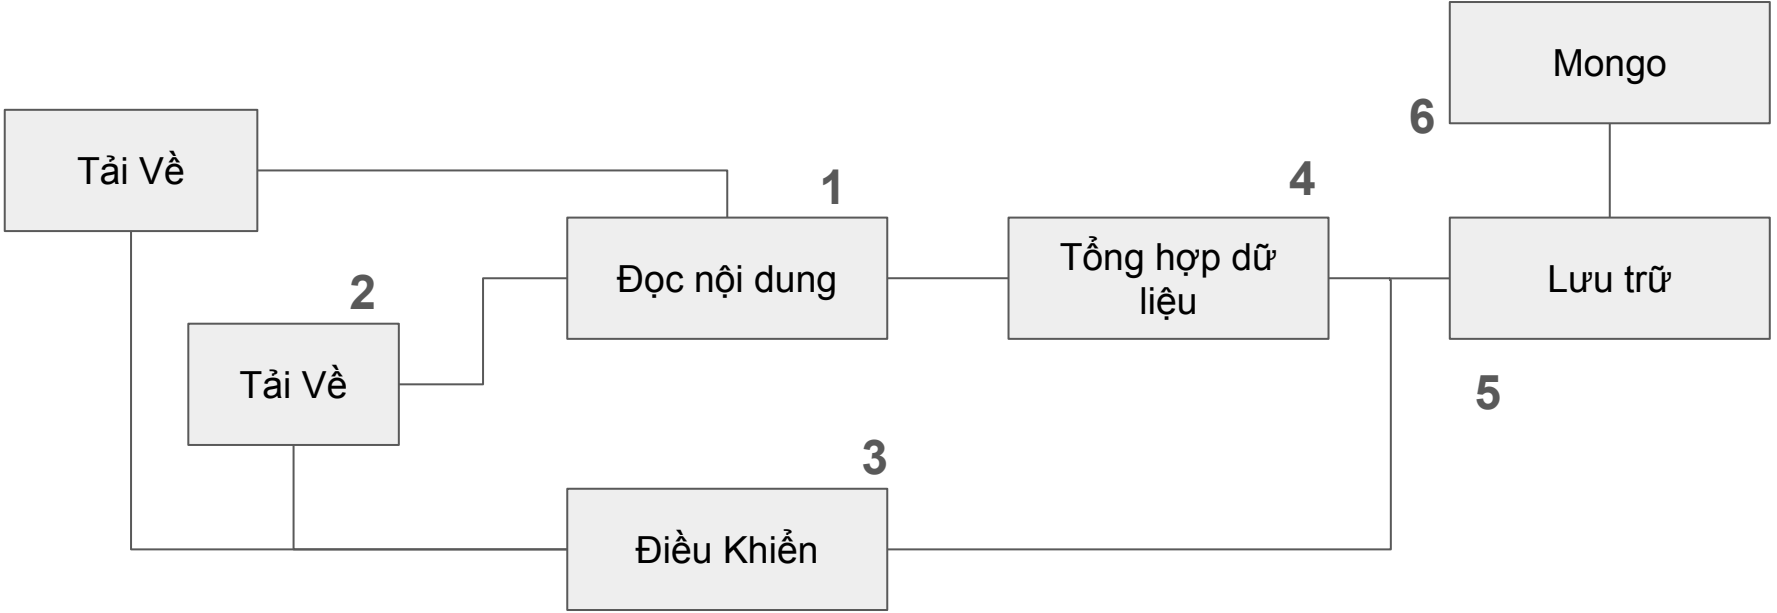
Đầu vào:

- uri: địa chỉ truy cập
- định dạng: other
- các trường nội dung

Xử lý:

- Lọc url - lấy trong miền hust
- Loại url đã có

Đầu ra:



Lưu trữ: Tiếp nhận dữ liệu và lưu vào Mongo theo đúng cấu trúc
Mongo: Dựng MongoDB

Đặc tả dịch vụ

Tổng hợp dữ liệu (GIC: N8)

Giao diện thêm nội dung

post: http://ip:cổng/add

{"url": "https://hust.edu.vn/tin-tuc1",

"format": "html"

"title": "Tin tức 1",

"content": "Nội dung tin tức bóc tách được",

"out-links": ["url đi ra", "văn bản liên kết"]

}

Lưu trữ (N10)

Giao diện thêm nội dung

post: http://ip:cổng/add

{"url": "https://hust.edu.vn/tin-tuc1",

"format": "html"

"title": "Tin tức 1",

"content": "Nội dung tin tức bóc tách được",

"out-links": ["url đi ra", "văn bản liên kết"]

}

Thêm dữ liệu vào Mongo

2	20261093M Đinh Thuỳ Anh
9	20261087M Phạm Duy Khánh
11	20251230M Ngô Văn Tấn Lưu
13	20252093M Nguyễn Nhật Minh

Mongo


```
{"html":
        [{"url": "https://hust.edu.vn/tin-tuc1",
        "format": "html"
        "title": "Tin tức 1",
        "content": "Nội dung tin tức bóc tách được",
        "intro": "Nội dung văn bản giới thiệu nếu có"}],
 "other":
    [{"url": "https://hust.edu.vn/tin-tuc1",
        "format": "docx",
        "url": "https://hust.edu.vn/tin-tuc1",
        "content": "html"
        }
     ],
  "graph": [{"src":  "https://hust.edu.vn/",
                "dest": "https://hust.edu.vn/tin-tuc1",
```

Điều khiển

Lệnh thêm url:

Post: http://ip:5200/add

{"urls": ["https://hust.edu.vn/tin-tuc1",

"https://hust.edu.vn/tin-tuc2",

"https://hust.edu.vn/tin-tuc3"]}

Tải về

Lệnh tải url về:

Post http://ip:/load

{"url": "https://hust.edu.vn/tin-tuc"}

Lệnh kiểm tra trạng thái:

Get http://ip:/ping

{"status": "đang chờ"}

Đọc nội dung

Lệnh đọc nội dung

post: http://ip:cổng/parse

http content - dữ liệu được tải về