Thu thập, bóc tách và tìm kiếm thông tin trên các website Đại học Bách khoa Hà Nội

IT4863 Tìm kiếm thông tin · Giảng viên: TS. Nguyễn Bá Ngọc

Nhóm BAT: Doãn Văn An · [Họ và tên] · [Họ và tên]

Nội dung

01

Giới thiệu

Đề bài và phạm vi thu thập

02

Thu thập và bóc tách

Năm dịch vụ, từ tải trang tới lưu MongoDB

03

Tìm kiếm với Lucene

Lập chỉ mục và tìm kiếm trên kho dữ liệu

04

Kết quả

Bộ dữ liệu thu được và kết quả tìm kiếm

01

Giới thiệu

Đề bài và phạm vi thu thập

Đề bài yêu cầu bóc tách gì

Trang web

Tiêu đề, ngày đăng, tác giả, nội dung, văn bản liên kết trỏ tới

Tệp ảnh

Trang chứa ảnh và dữ liệu ảnh

Tệp tài liệu

Nội dung văn bản và trang dẫn tới tài liệu

Đồ thị liên kết

Từ trang nguồn tới trang đích, kèm văn bản mô tả liên kết

77 website

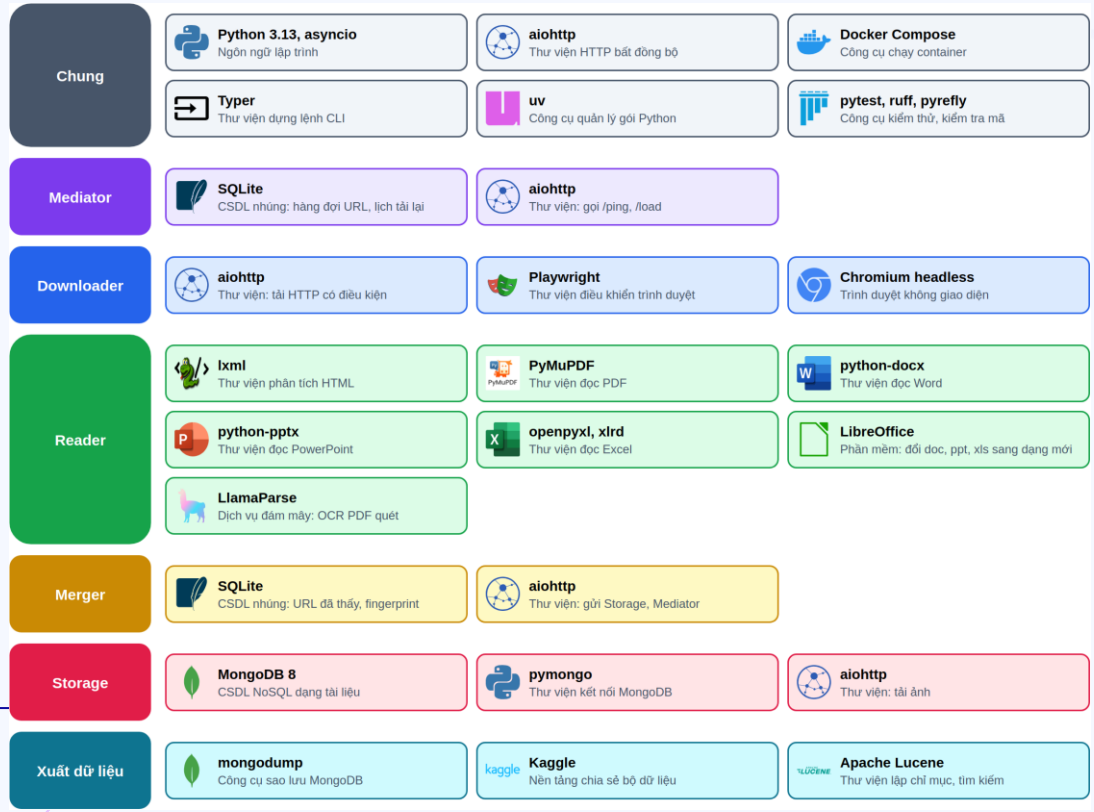
chọn từ 603 tên miền của trường làm điểm bắt đầu thu thập

02

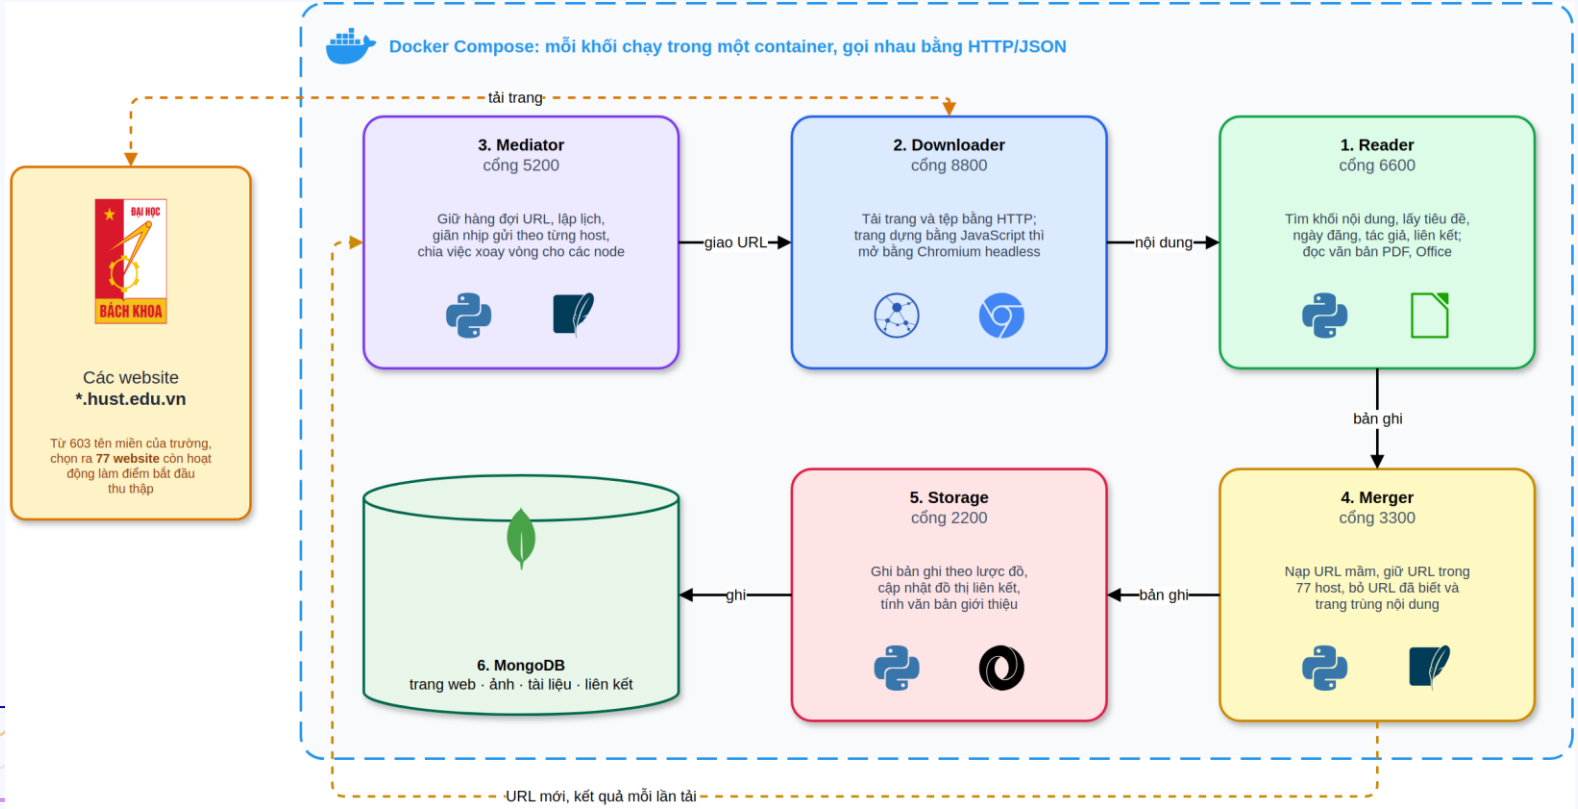
Thu thập dữ liệu

Năm dịch vụ theo kiến trúc của thầy

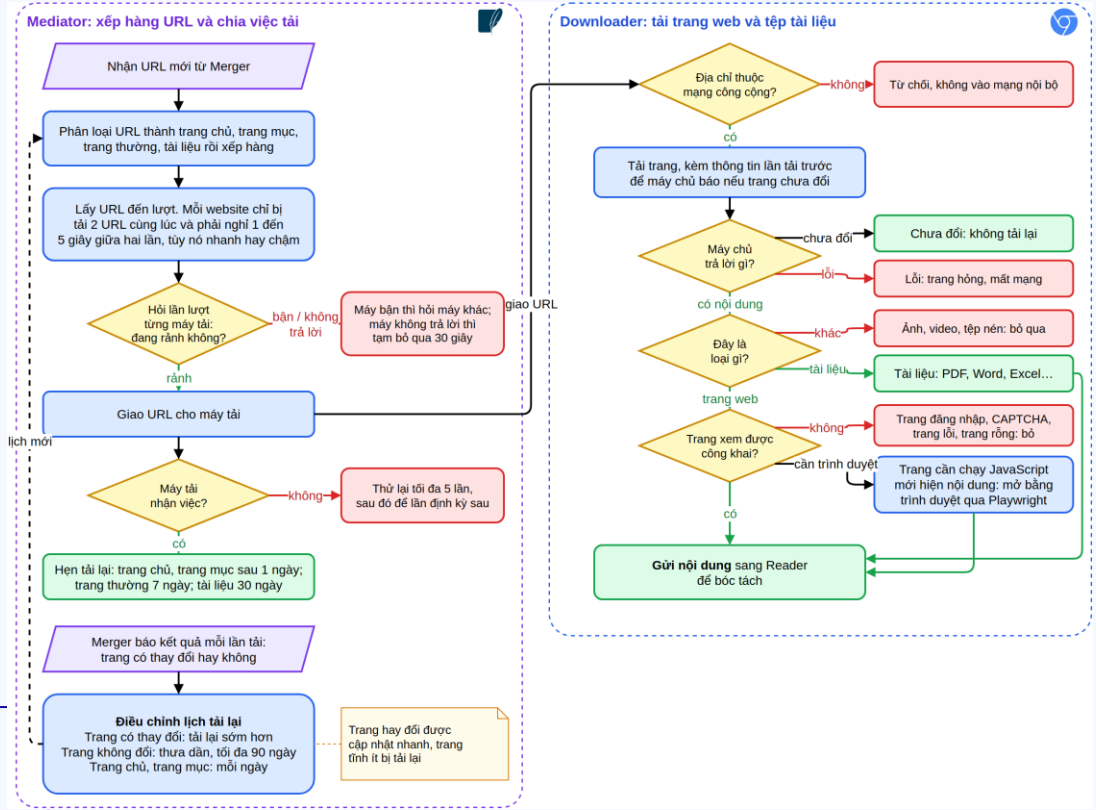
Công nghệ sử dụng



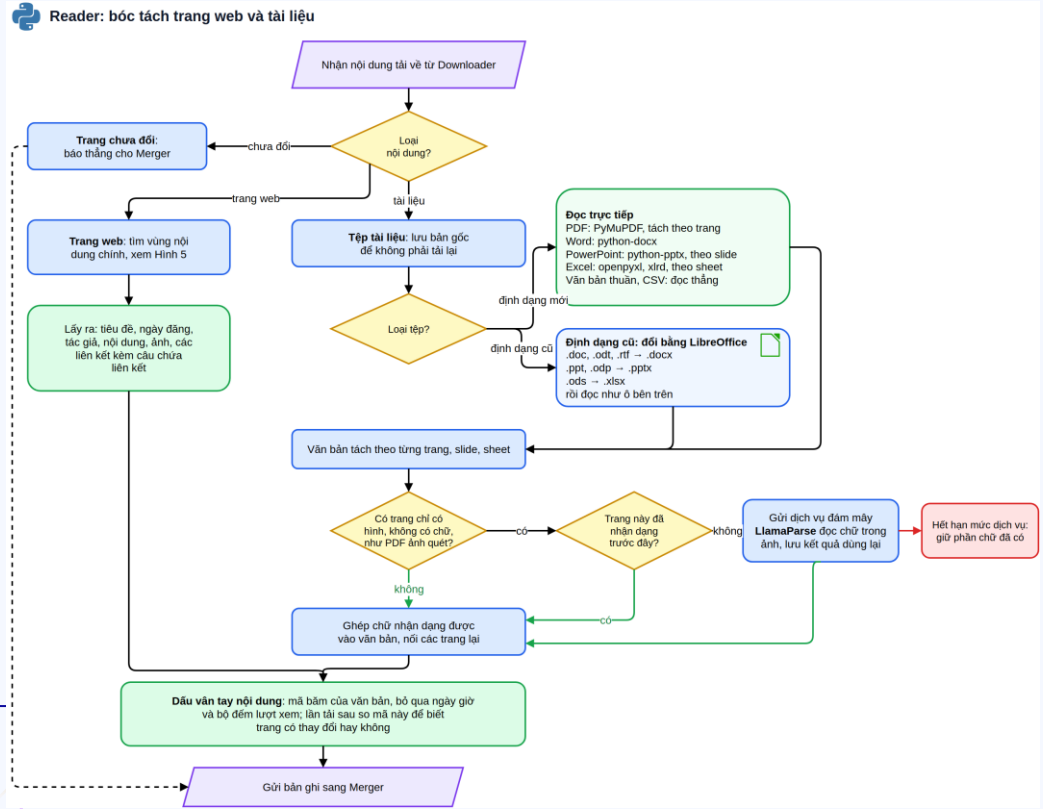
Kiến trúc tổng thể



Điều phối, tải và lập lịch

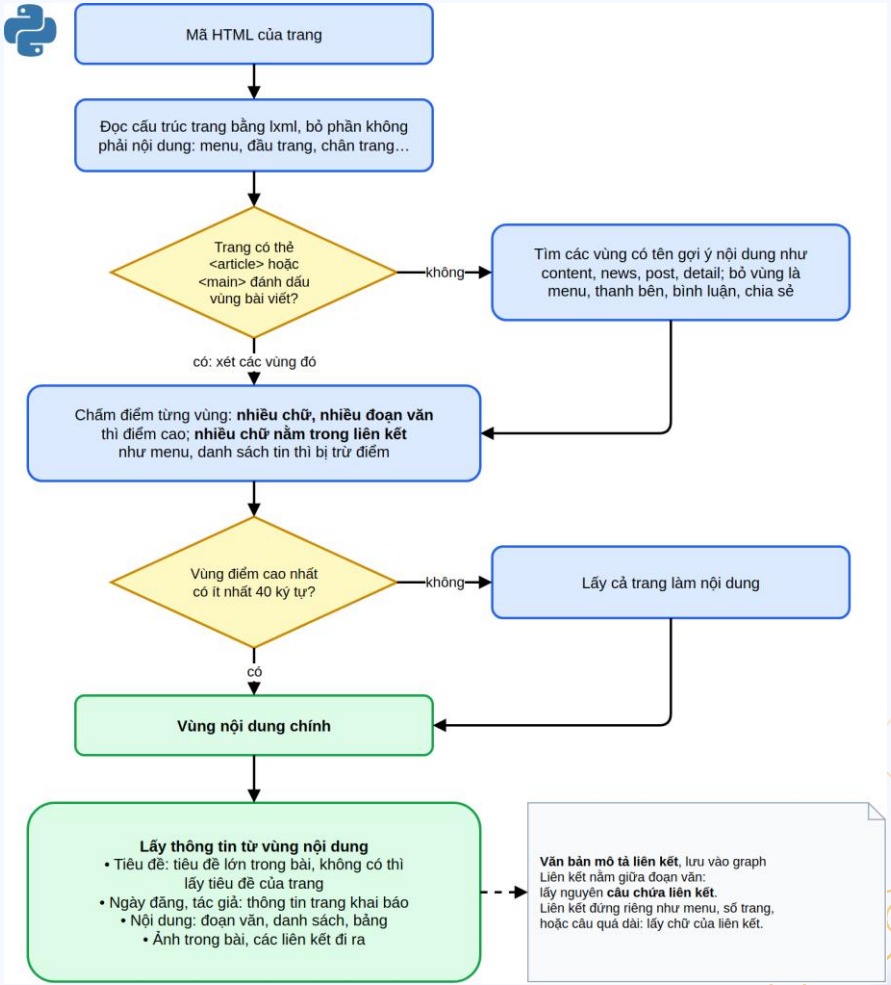


Bóc tách trang web và tài liệu



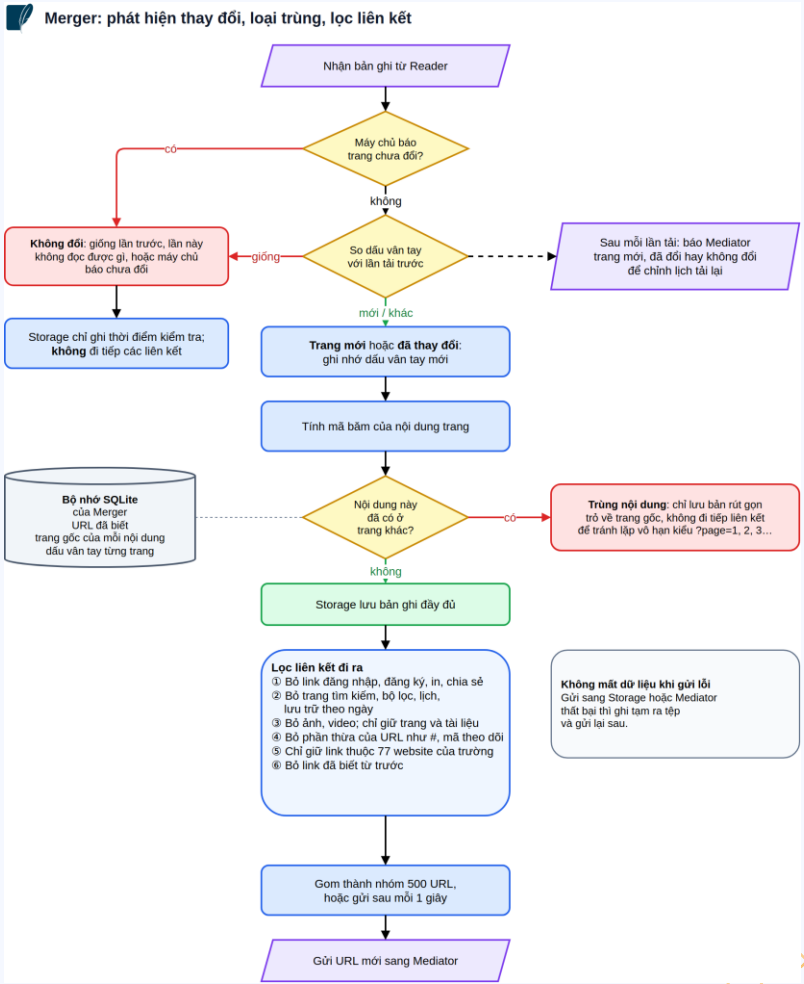
Tìm vùng nội dung chính

Trang web có menu, thanh bên, chân trang lẫn với bài viết.
Mỗi vùng được chấm điểm: nhiều chữ, nhiều đoạn văn thì cao; nhiều chữ trong liên kết thì bị trừ.
Vùng điểm cao nhất là bài viết.



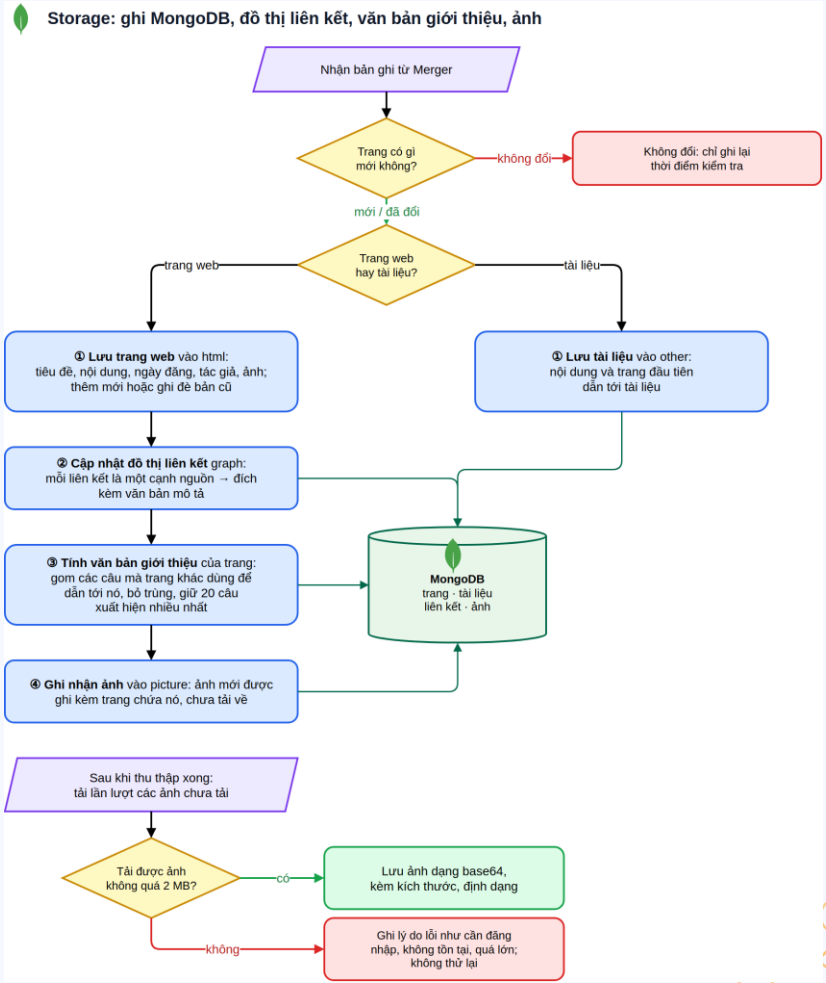
Loại trùng và phát hiện thay đổi

Trang trùng nội dung chỉ lưu bản rút gọn trỏ về trang gốc.
Trang không đổi chỉ ghi thời điểm kiểm tra.
Liên kết mới qua sáu bước lọc trước khi đưa vào hàng đợi.

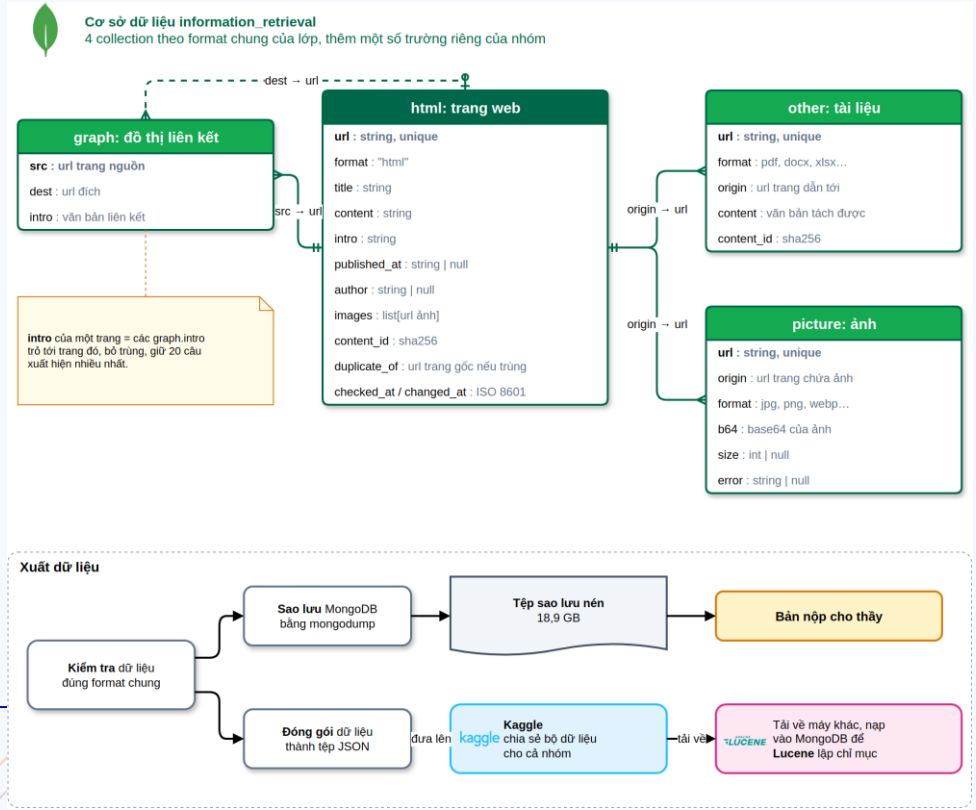


Lưu trữ vào MongoDB

Lưu trang web, tài liệu và đồ thị liên kết.
Văn bản giới thiệu của một trang gom từ các câu trang khác dùng để dẫn tới nó.
Ảnh được tải sau khi thu thập xong.



Lược đồ dữ liệu và xuất dữ liệu



03

Tìm kiếm Lucene

[Phần do thành viên phụ trách Lucene điền]

Tiền xử lý văn bản tiếng Việt

[Nội dung phần Lucene]

[Hình hoặc ví dụ minh họa]

Lập chỉ mục

[Nội dung phần Lucene]

[Hình hoặc ví dụ minh họa]

Tìm kiếm và xếp hạng

[Nội dung phần Lucene]

[Hình hoặc ví dụ minh họa]

04

Kết quả

Bộ dữ liệu thu được và kết quả tìm kiếm

141.353 trang

từ 80 website, kèm 5.860 tệp tài liệu

114.476 ảnh

98.274 ảnh tải được, đạt 85,8%

8,25 triệu

liên kết giữa các trang trong đồ thị

Kết quả tìm kiếm

[Nội dung phần Lucene]

[Hình hoặc ví dụ minh họa]

Cảm ơn!