Thu thập, bóc tách và tìm kiếm thông tin trên các website Đại học Bách khoa Hà Nội

IT4863 Tìm kiếm thông tin · Giảng viên: TS. Nguyễn Bá Ngọc

Nhóm BAT: Doãn Văn An · Trần Ngọc Bảo · Phạm Sơn Tùng

Nội dung

01
Giới thiệu
Đề bài và phạm vi thu thập

02
Thu thập và bóc tách
Năm dịch vụ, từ tải trang tới lưu MongoDB

03
Tìm kiếm với Lucene
Lập chỉ mục và tìm kiếm trên kho dữ liệu

04
Kết quả
Bộ dữ liệu thu được và kết quả tìm kiếm

01

Giới thiệu

Đề bài và phạm vi thu thập

Đề bài yêu cầu bóc tách gì

Trang web

Tiêu đề, ngày đăng, tác giả, nội dung, văn bản liên kết trỏ tới

Tệp ảnh

Trang chứa ảnh và dữ liệu ảnh

Tệp tài liệu

Nội dung văn bản và trang dẫn tới tài liệu

Đồ thị liên kết

Từ trang nguồn tới trang đích, kèm văn bản mô tả liên kết

77 website

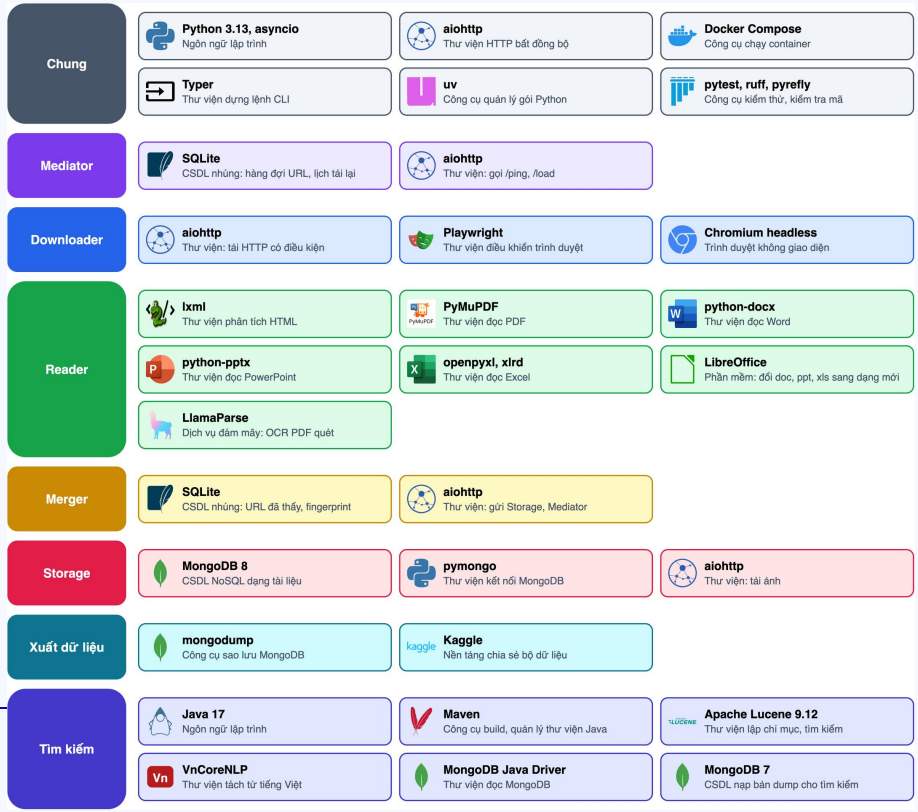
chọn từ 603 tên miền của trường làm điểm bắt đầu thu thập

02

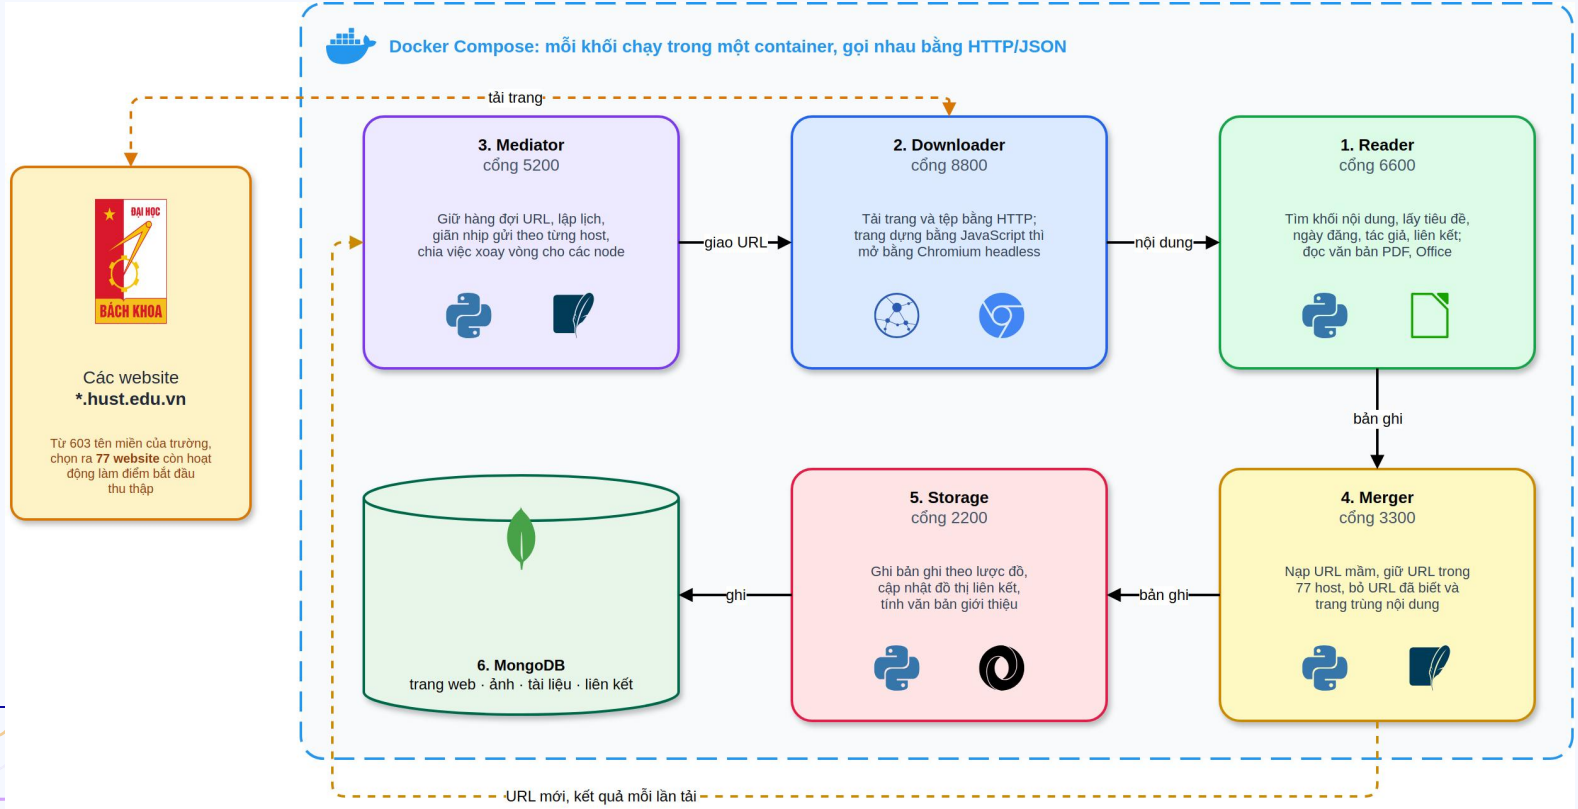
Thu thập dữ liệu

Năm dịch vụ theo kiến trúc của thầy

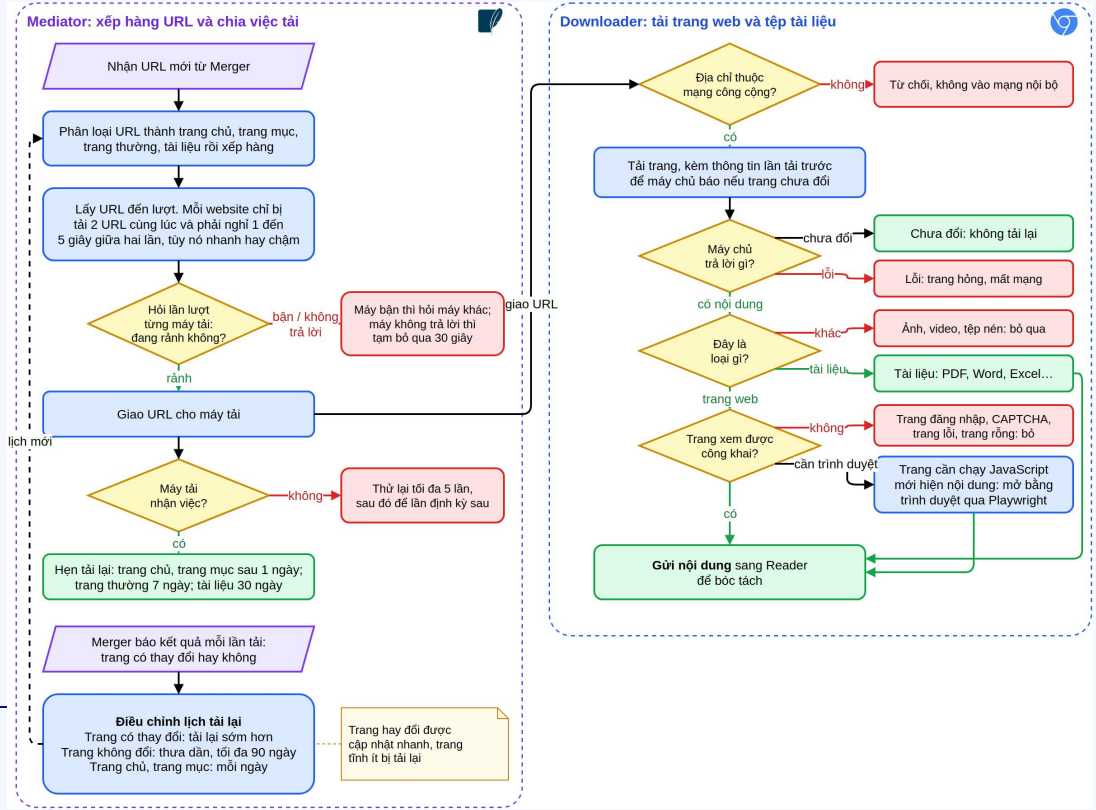
Công nghệ sử dụng



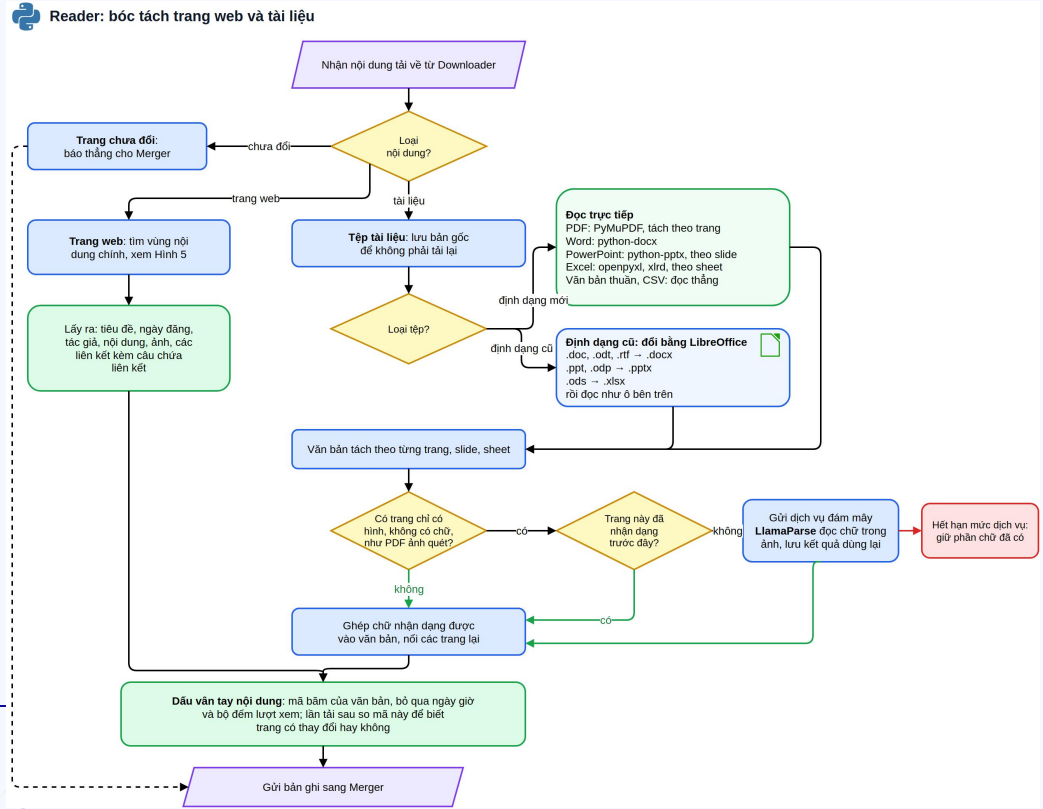
Kiến trúc tổng thể



Điều phối, tải và lập lịch

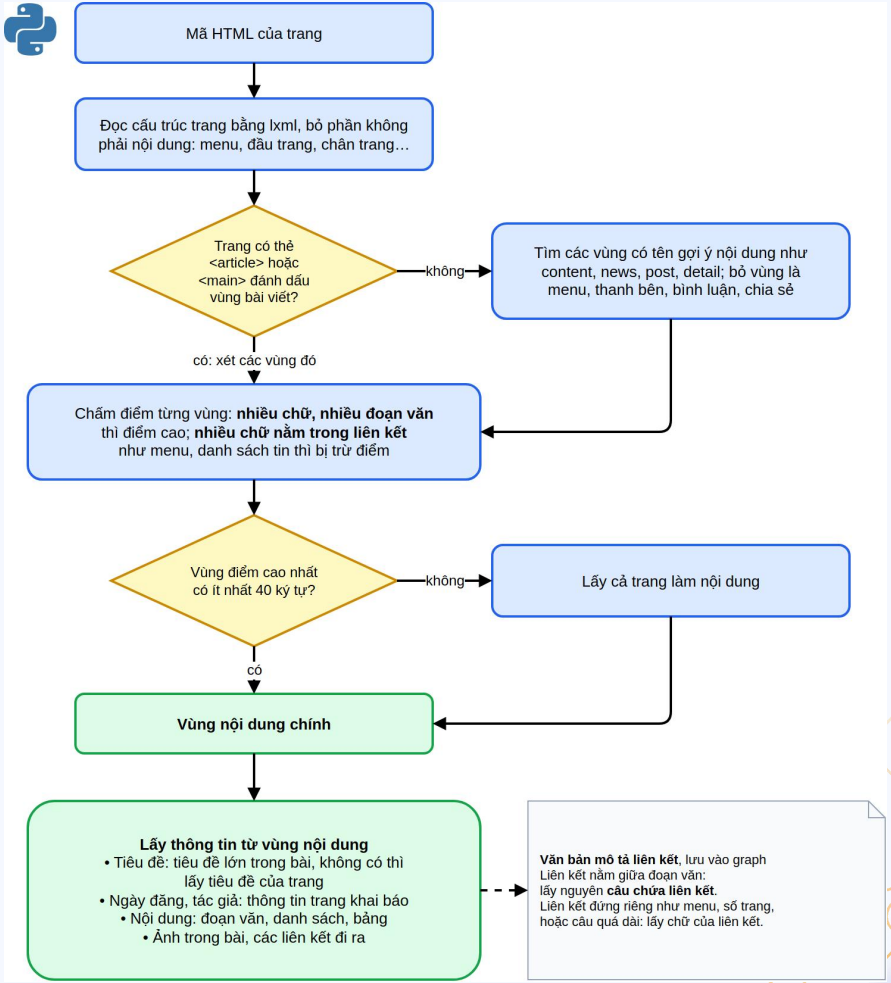


Bóc tách trang web và tài liệu



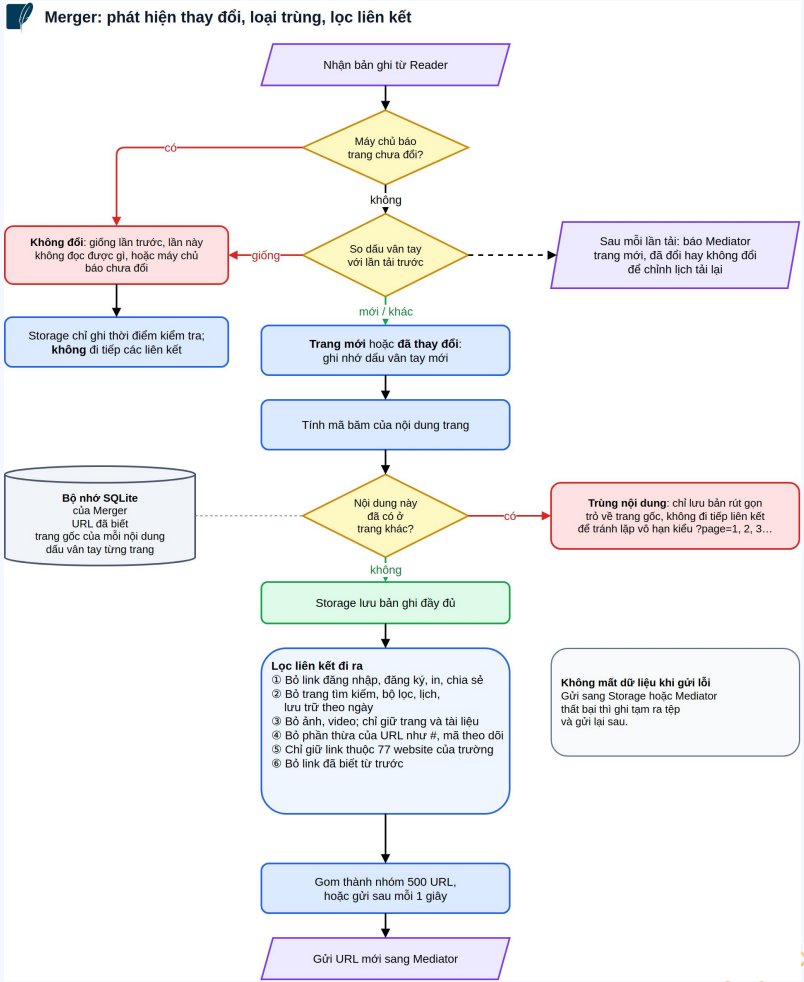
Tìm vùng nội dung chính

Trang web có menu, thanh bên, chân trang lẫn với bài viết.
Mỗi vùng được chấm điểm: nhiều chữ, nhiều đoạn văn thì cao; nhiều chữ trong liên kết thì bị trừ.
Vùng điểm cao nhất là bài viết.



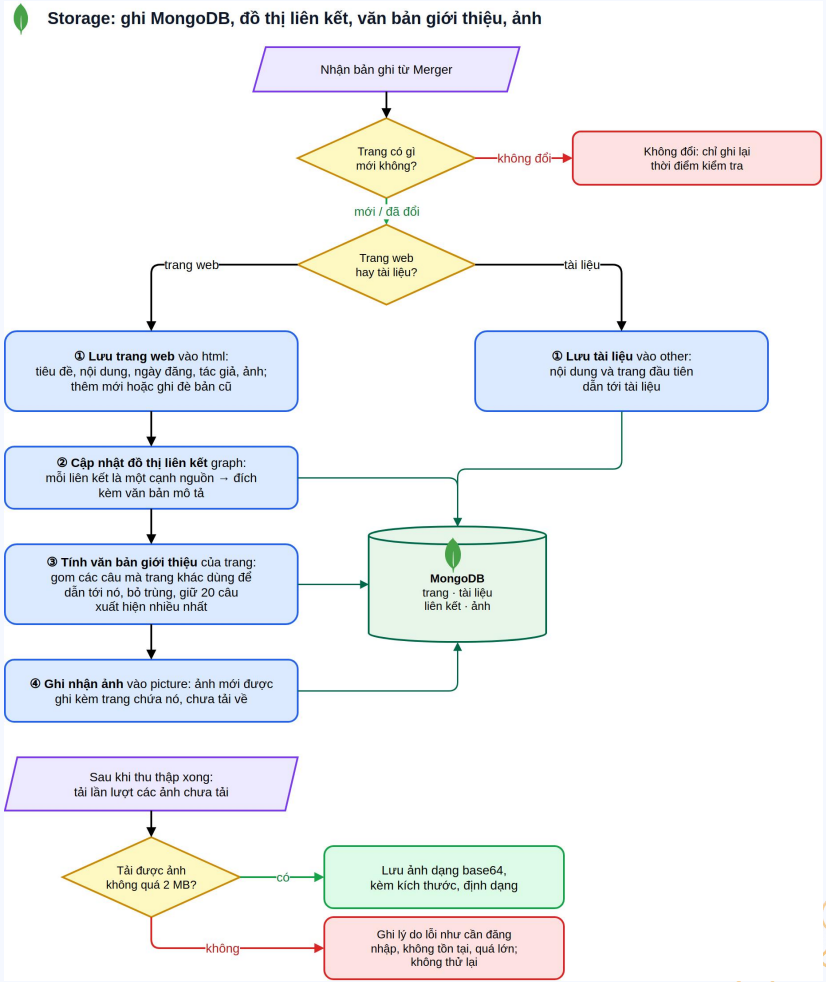
Loại trùng và phát hiện thay đổi

Trang trùng nội dung chỉ lưu bản rút gọn trỏ về trang gốc.
Trang không đổi chỉ ghi thời điểm kiểm tra.
Liên kết mới qua sáu bước lọc trước khi đưa vào hàng đợi.

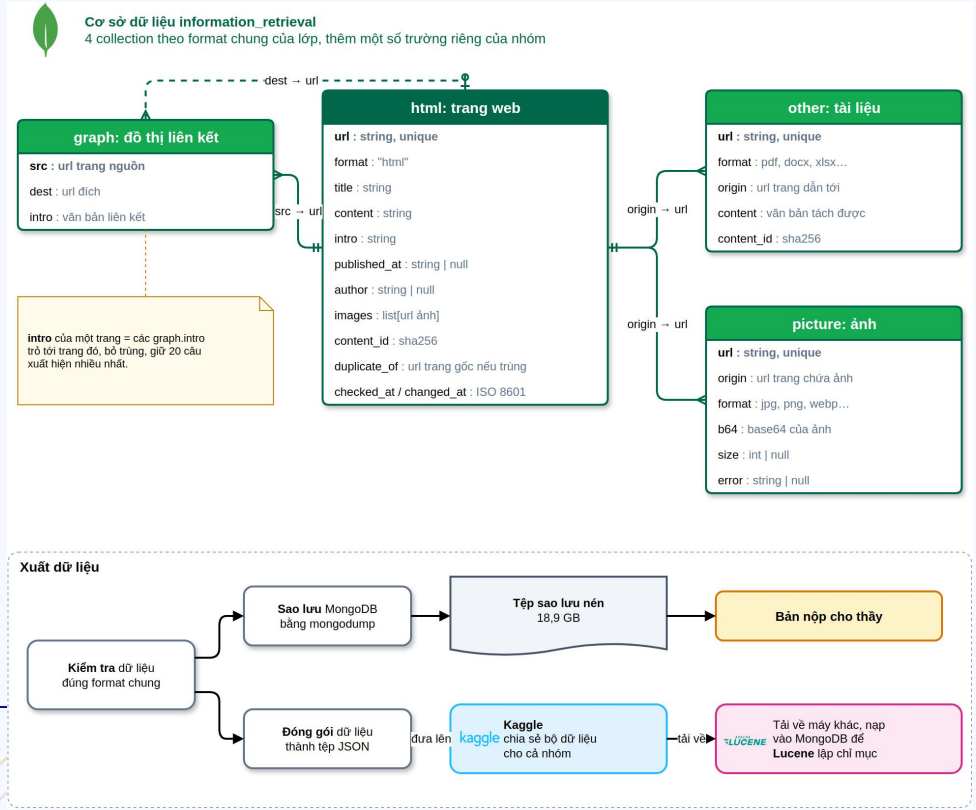


Lưu trữ vào MongoDB

Lưu trang web, tài liệu và đồ thị liên kết.
Văn bản giới thiệu của một trang gom từ các câu trang khác dùng để dẫn tới nó.
Ảnh được tải sau khi thu thập xong.



Lược đồ dữ liệu và xuất dữ liệu

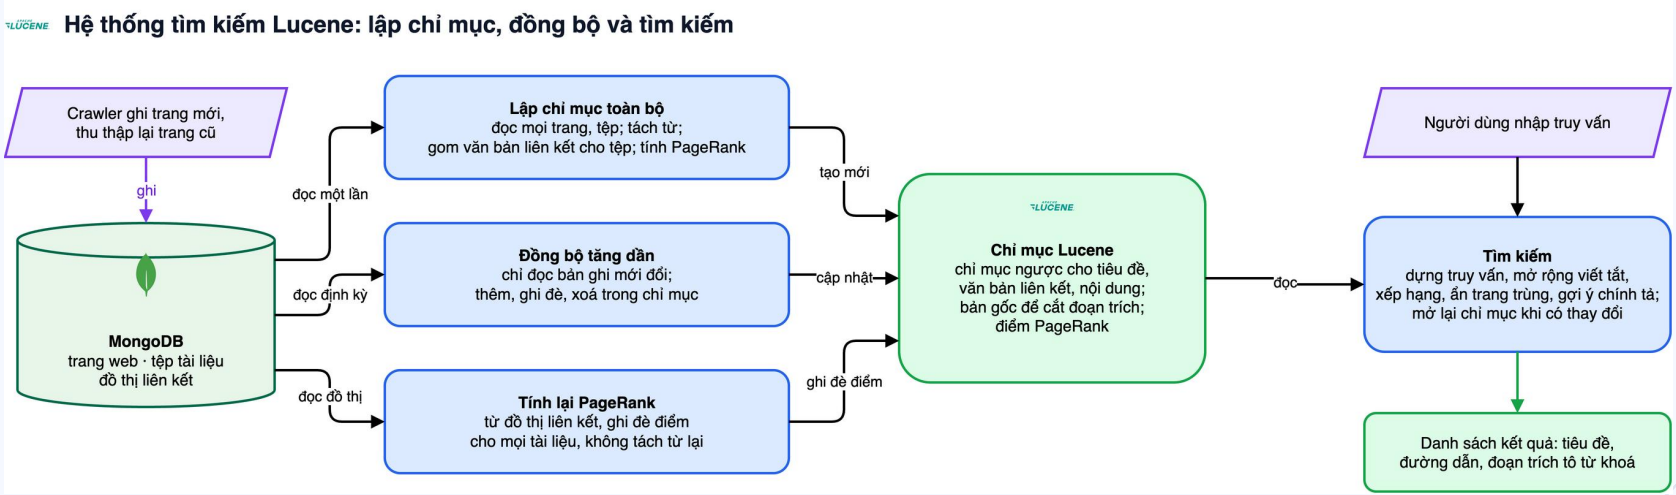


03

Tìm kiếm Lucene

Lập chỉ mục và tìm kiếm trên kho dữ liệu

Kiến trúc tìm kiếm



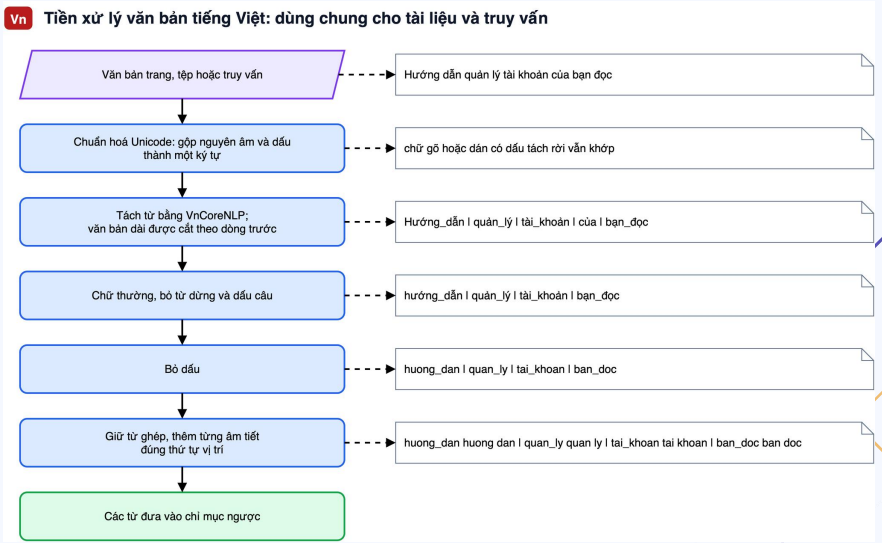
Tiền xử lý văn bản tiếng Việt

Tài liệu và truy vấn đi qua cùng một chuỗi bước.

VnCoreNLP gộp âm tiết thành từ; văn bản dài được cắt theo dòng trước khi tách.

Bỏ dấu, nên gõ không dấu vẫn tìm được.

Giữ từ ghép và thêm từng âm tiết, để khớp theo cụm khi cách tách từ lệch nhau.



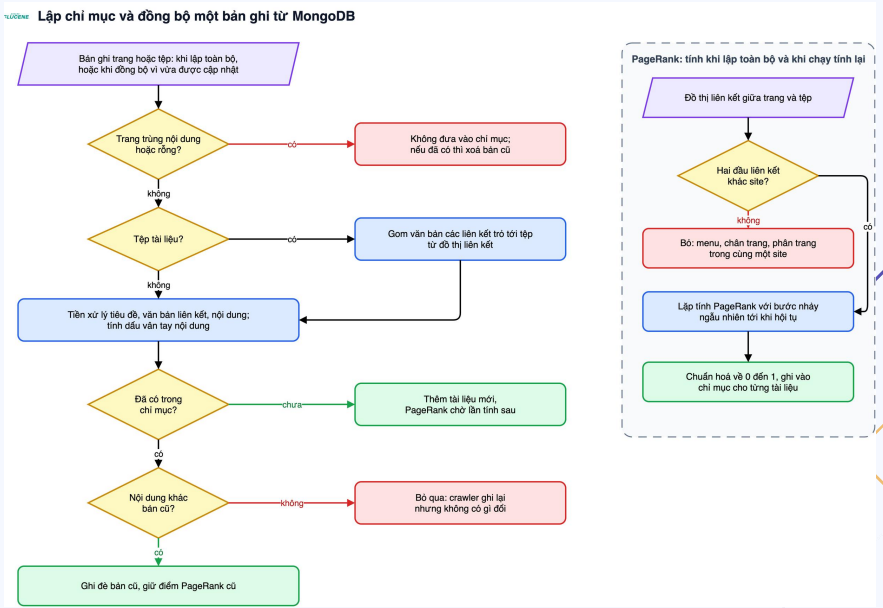
Lập chỉ mục

Mỗi trang, mỗi tệp là một tài liệu, khoá là URL; trang trùng nội dung bị bỏ.

Tệp PDF được gắn văn bản của các liên kết trỏ tới nó.

Đồng bộ chỉ đọc bản ghi vừa đổi: thêm, ghi đè hoặc xoá.

PageRank tính trên liên kết giữa các site khác nhau.



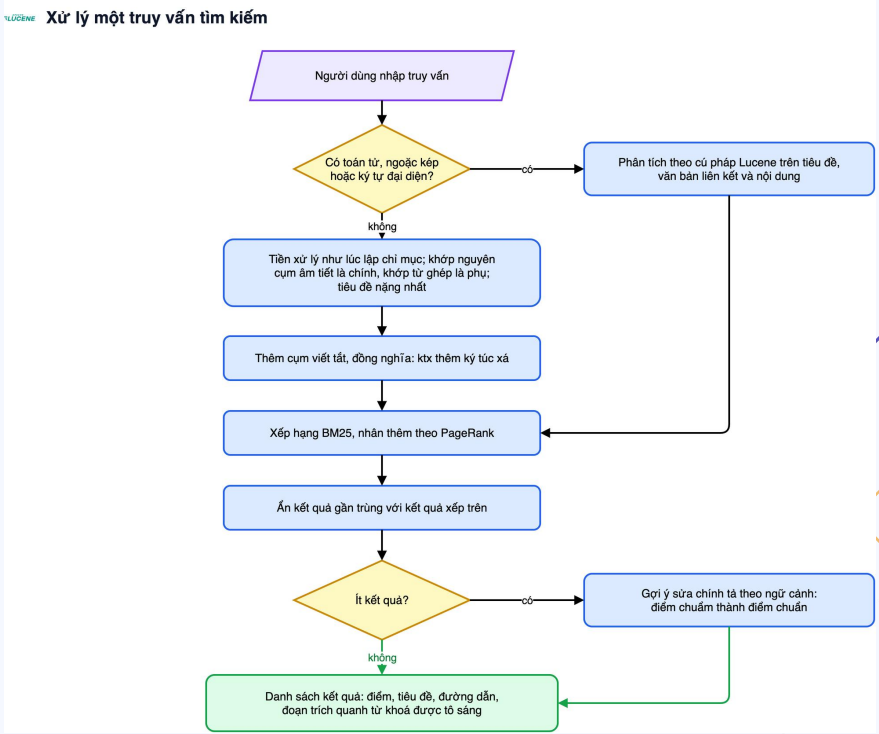
Tìm kiếm và xếp hạng

Truy vấn trơn là một cụm: âm tiết đứng liền nhau là chính, từ ghép là phụ.

Tiêu đề nặng gấp ba nội dung.

Thêm viết tắt của trường, như ktx thành ký túc xá.

BM25 nhân thêm theo PageRank; ẩn kết quả gần trùng; gợi ý chính tả khi ít kết quả.



04

Kết quả

Bộ dữ liệu thu được và kết quả tìm kiếm

141.353 trang

từ 80 website, kèm 5.860 tệp tài liệu

114.476 ảnh

98.274 ảnh tải được, đạt 85,8%

8,25 triệu

liên kết giữa các trang trong đồ thị

Kết quả tìm kiếm

116.132 tài liệu, chỉ mục 398 MB, lập trong 635 giây.

Khoảng 0,13 giây mỗi truy vấn.

Đồng bộ một đợt 161 bản ghi trong 1,1 giây.



Cảm ơn!