Thu thập, bóc tách và tìm kiếm thông tin trên các website Đại học Bách khoa Hà Nội

IT4863 Tìm kiếm thông tin · Giảng viên: TS. Nguyễn Bá Ngọc

Nhóm BAT: Doãn Văn An · Trần Ngọc Bảo · Phạm Sơn Tùng

Nội dung

01
Giới thiệu
Bốn loại dữ liệu cần bóc tách

02
Thu thập và bóc tách
Năm dịch vụ, từ tải trang tới lưu MongoDB

03
Tìm kiếm với Lucene
Lập chỉ mục và tìm kiếm trên kho dữ liệu

04
Kết quả
Bộ dữ liệu thu được và kết quả tìm kiếm

01

Giới thiệu

Bốn loại dữ liệu cần bóc tách

Bốn loại dữ liệu cần bóc tách

Trang web

Tiêu đề, ngày đăng, tác giả, nội dung, văn bản liên kết trỏ tới

Tệp tài liệu

Nội dung văn bản và trang dẫn tới tài liệu

Tệp ảnh

Trang chứa ảnh và dữ liệu ảnh

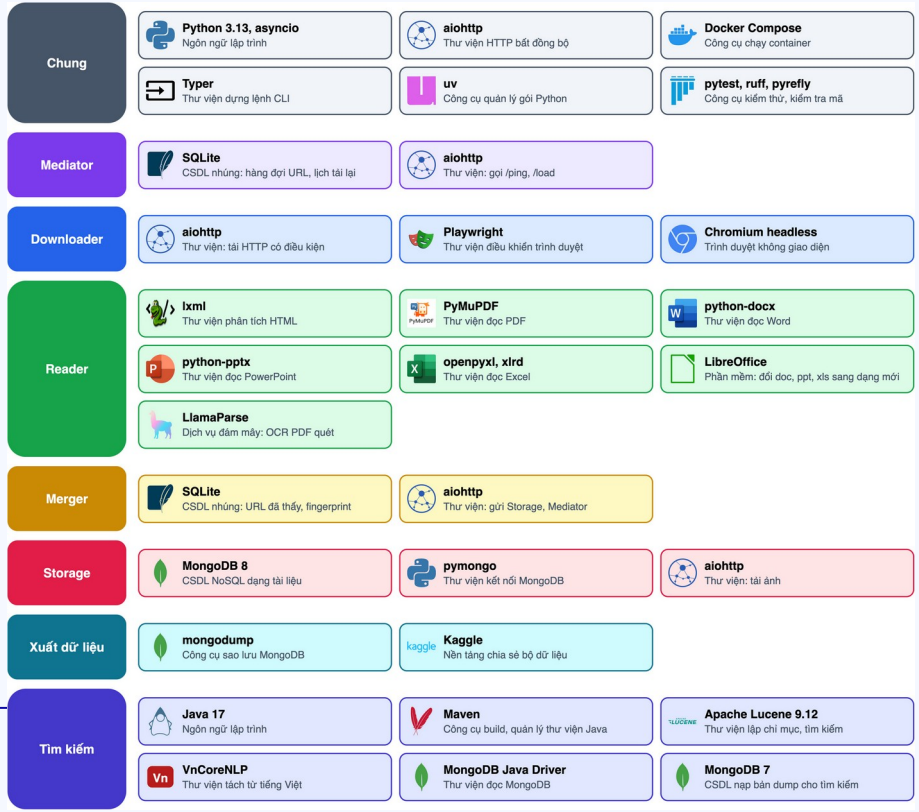
Đồ thị liên kết

Từ trang nguồn tới trang đích, kèm văn bản mô tả liên kết

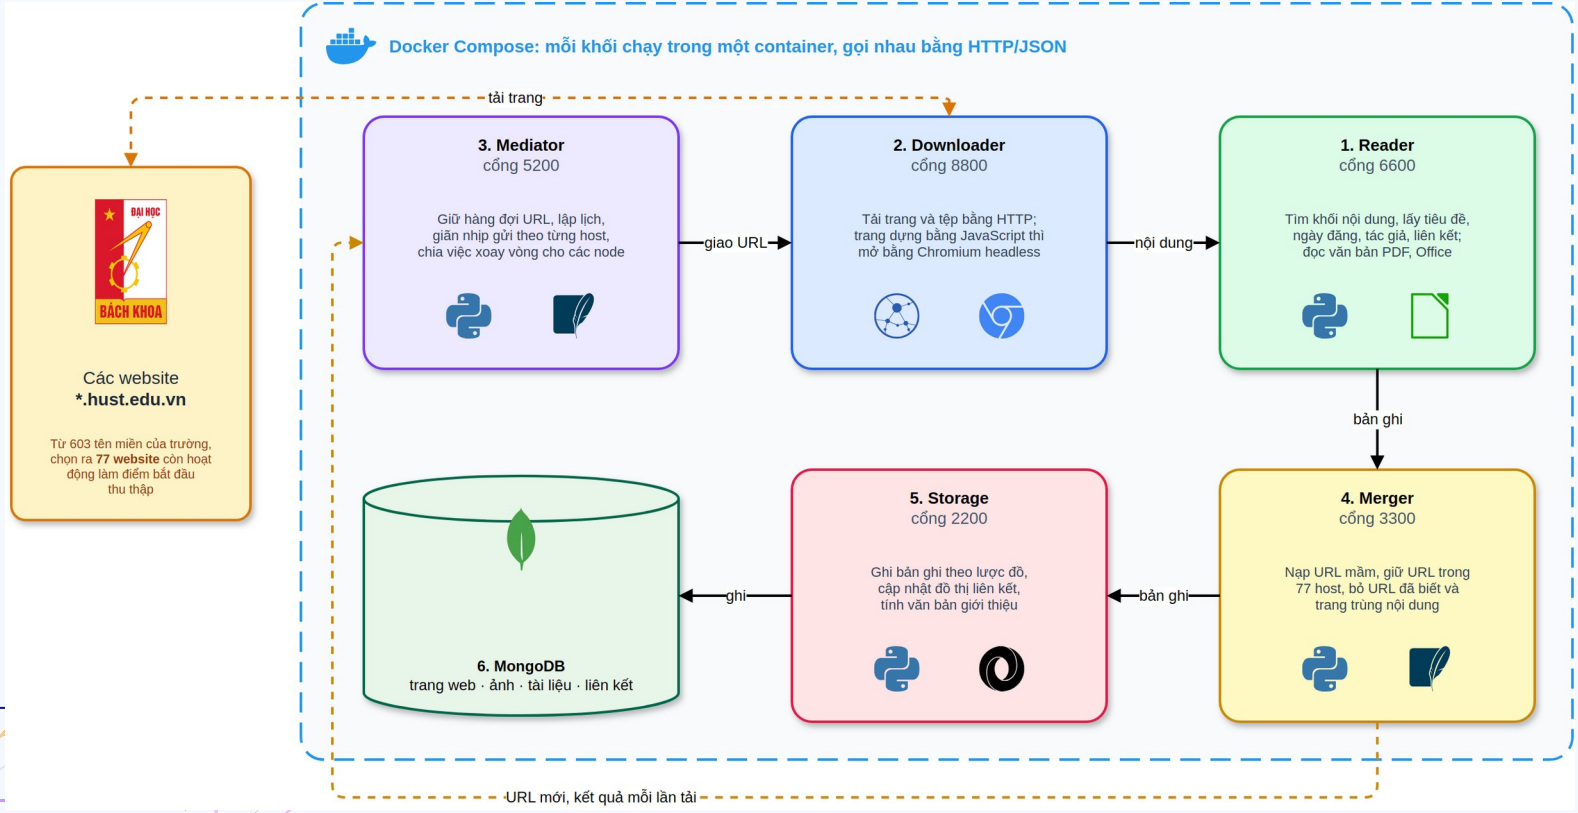
02

Thu thập dữ liệu

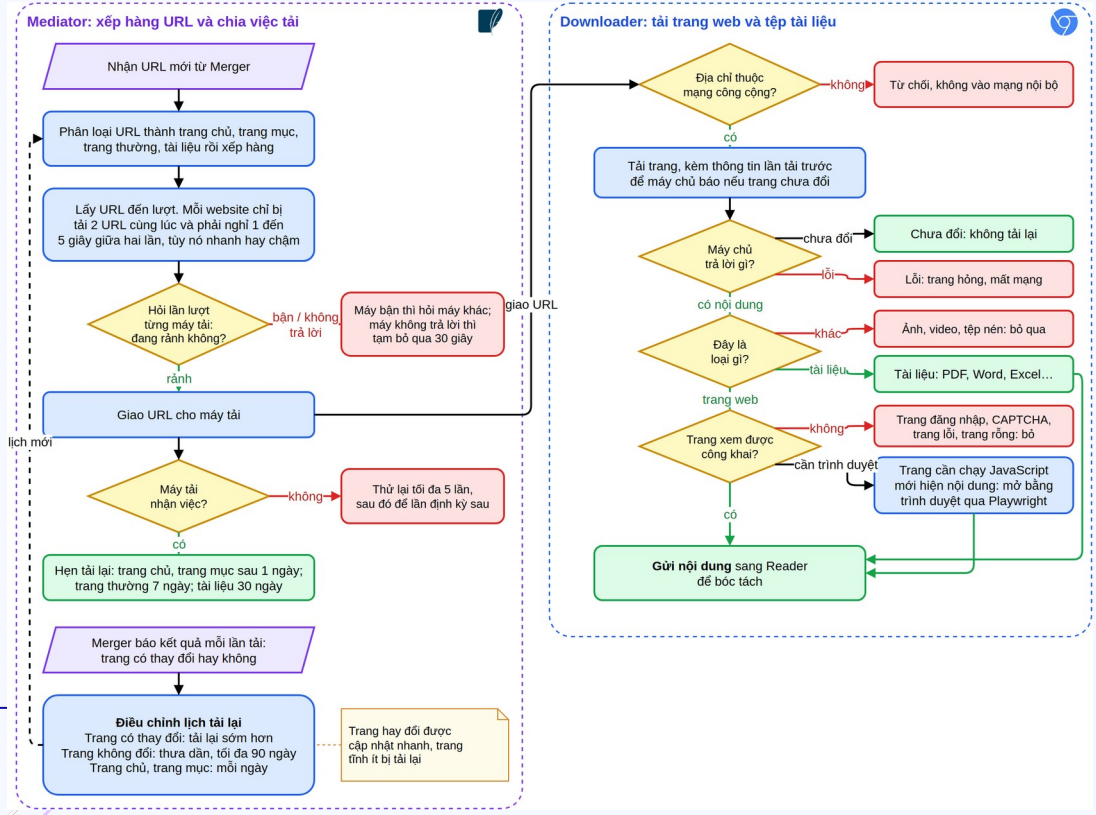
Công nghệ sử dụng



Kiến trúc tổng thể



Điều phối, tải và lập lịch



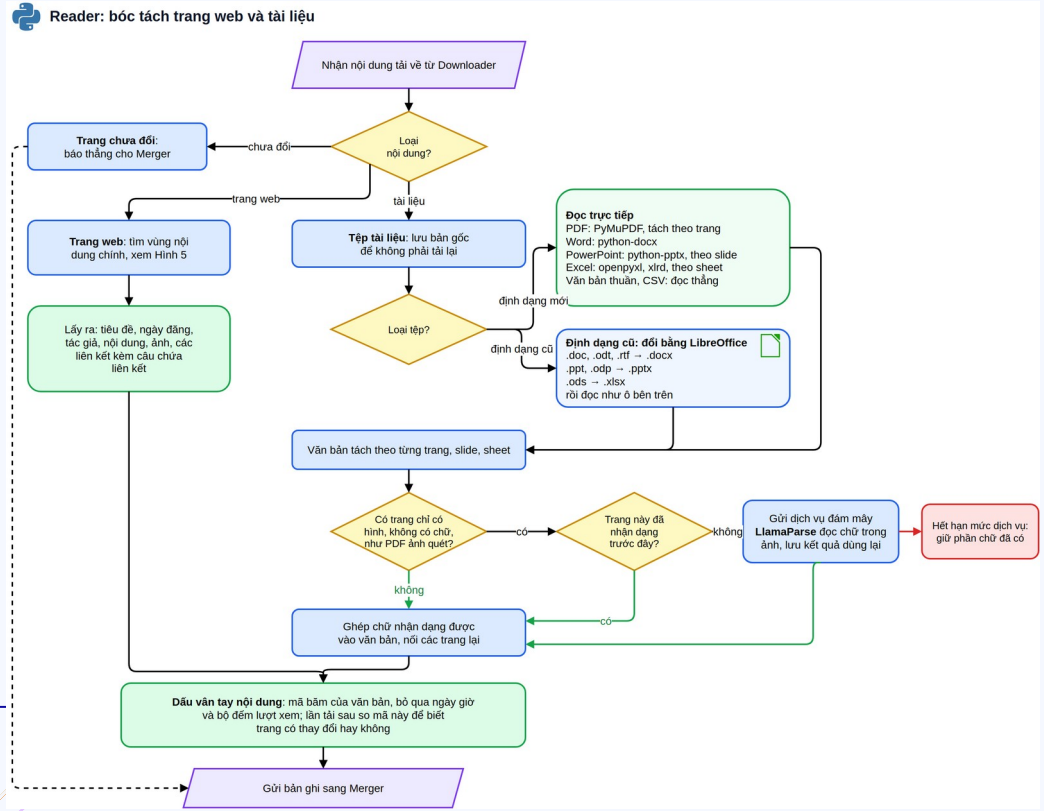
Phân loại URL và lịch tải lại

Loại URL	Nhận biết từ đường dẫn	Tải lại sau	Các lần sau
Trang chủ	/, /vi hoặc /en	1 ngày	Luôn giữ 1 ngày, vì bài mới xuất hiện ở đây trước
Trang mục	Đoạn cuối là tin-tuc, thong-bao, news...	1 ngày	
Trang thường	Các URL còn lại	7 ngày	Không đổi: giãn gấp đôi, tối đa 90 ngày Có đổi: giảm một nửa, không dưới chu kỳ gốc
Tài liệu	Đuôi .pdf, .docx, .xlsx...	30 ngày	

Xem lại thường xuyên nơi có bài mới, giảm tải cho website của trường: chỉ 892 trong hơn 160.000 URL là loại tải lại mỗi ngày.

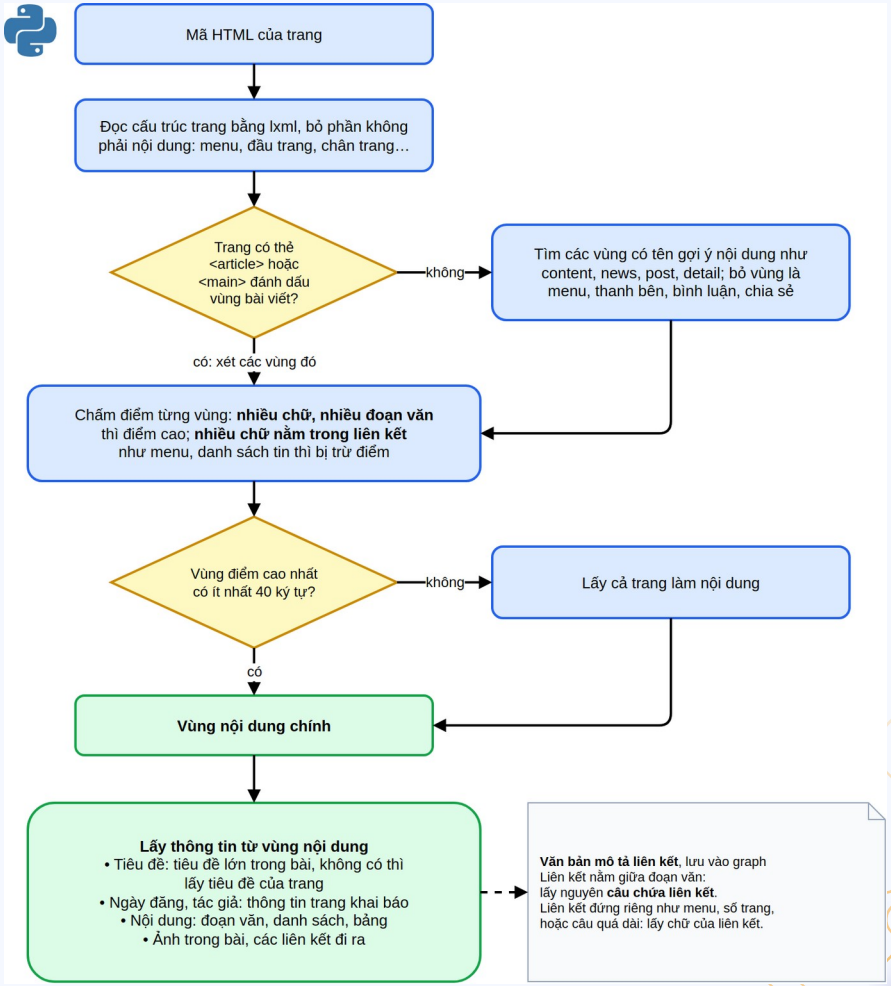
Phân loại chỉ quyết định lịch tải lại; hàng đợi vẫn lấy URL theo thời điểm đến hạn.

Bóc tách trang web và tài liệu



Tìm vùng nội dung chính

Trang web có menu, thanh bên, chân trang lẫn với bài viết.
Mỗi vùng được chấm điểm: nhiều chữ, nhiều đoạn văn thì cao; nhiều chữ trong liên kết thì bị trừ.
Vùng điểm cao nhất là bài viết.



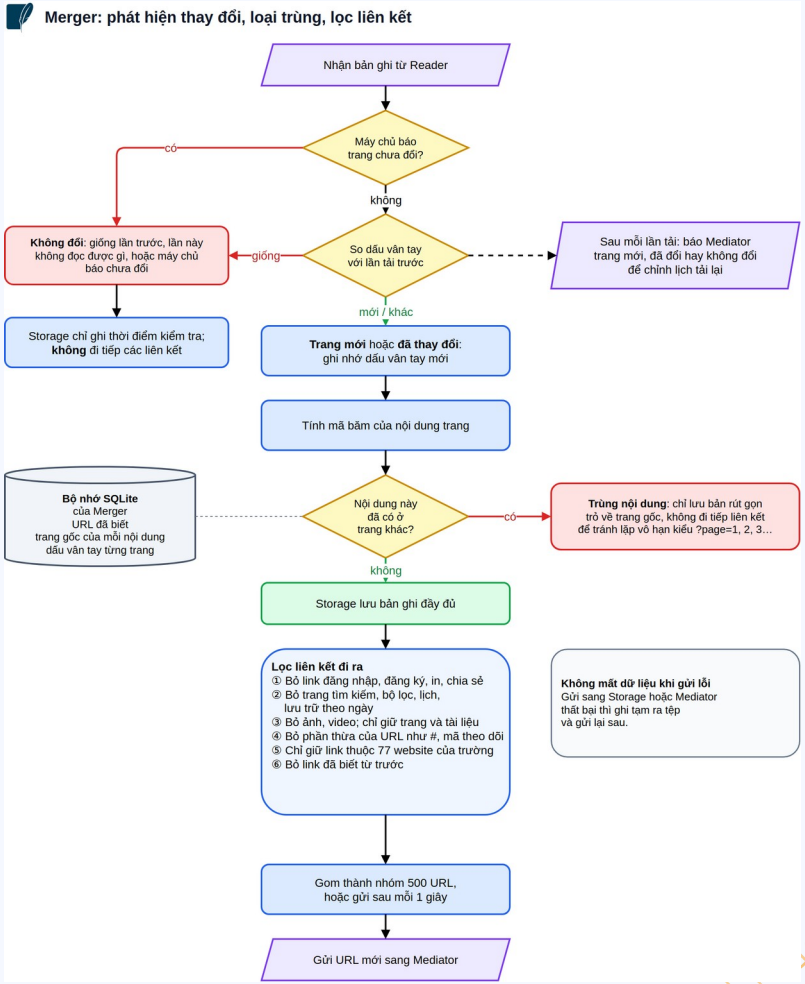
Cách bóc tách từng trường

Trường	Lấy từ đâu, theo thứ tự ưu tiên
Nội dung	article, main, rồi class gợi ý nội dung; chọn vùng điểm cao nhất, bỏ menu, chân trang
Tiêu đề	h1 trong vùng nội dung, og:title, title, rồi h1 bất kỳ
Ngày đăng	Thẻ meta article:published_time, pubdate, rồi thẻ time
Tác giả	Thẻ meta author, article:author
Ảnh	img, picture trong vùng nội dung
Đồ thị liên kết	Mọi liên kết trong cả trang, kèm câu chứa liên kết

Đọc HTML thành cây thẻ bằng lxml rồi lấy từng trường bằng XPath. Regex chỉ dùng cho việc nhỏ như xem tên class hay tách câu.

Loại trùng và phát hiện thay đổi

Trang trùng nội dung chỉ lưu bản rút gọn trỏ về trang gốc.
Trang không đổi chỉ ghi thời điểm kiểm tra.
Liên kết mới qua sáu bước lọc trước khi đưa vào hàng đợi.

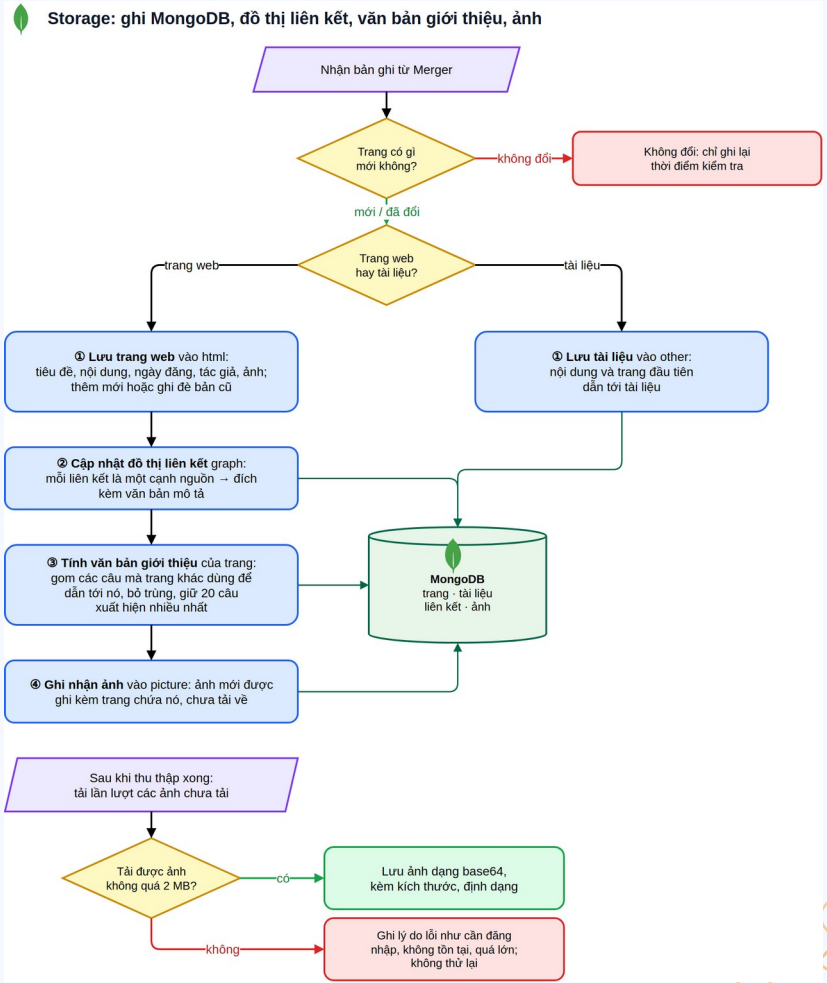


Ngăn chặn lan vô tận, trùng lặp

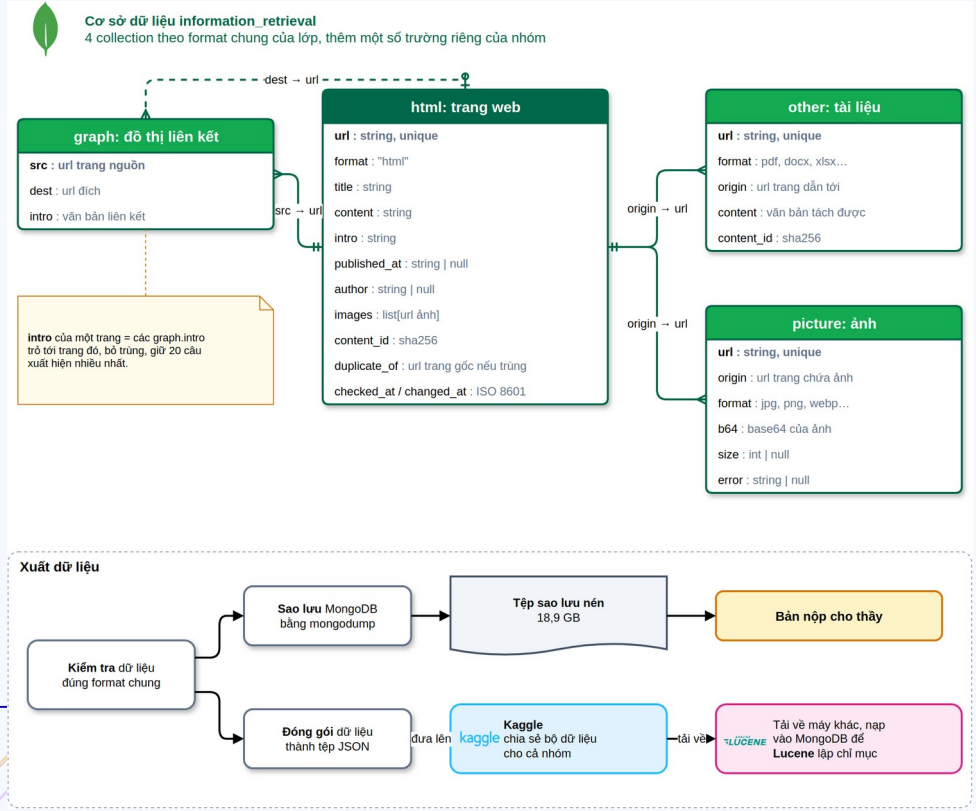
Ngăn chặn	Cách làm	Ví dụ
Lan vô tận	Chỉ đi trong 77 website đã chọn	baochinhphu.vn/bai.html
	Bỏ tìm kiếm, bộ lọc, sắp xếp, lịch	/tim?q=abc, /tin-tuc?sort=date
	Bỏ đăng nhập, in, chia sẻ, RSS, API, ảnh, video	/login, /feed, /anh.jpg
	Bỏ đường dẫn lặp 4 đoạn giống nhau	/a/a/a/a
	Trang trùng là ngõ cụt; trang không đổi không lan lại	?page=N luôn trả cùng một trang
Trùng lặp	Đưa URL về dạng chuẩn, bỏ URL đã biết	bai.html#binh-luan và bai.html?utm_source=fb là một
	Băm SHA-256 văn bản; URL đầu tiên là trang gốc, URL sau chỉ lưu bản rút gọn	27.730 bản rút gọn trong 141.353 trang
	So dấu vân tay với lần tải trước; giống thì chỉ ghi thời điểm kiểm tra	Đổi ngày tháng, lượt xem không tính là đổi

Lưu trữ vào MongoDB

Lưu trang web, tài liệu và đồ thị liên kết.
Văn bản giới thiệu của một trang gom từ các câu trang khác dùng để dẫn tới nó.
Ảnh được tải sau khi thu thập xong.



Lược đồ dữ liệu và xuất dữ liệu

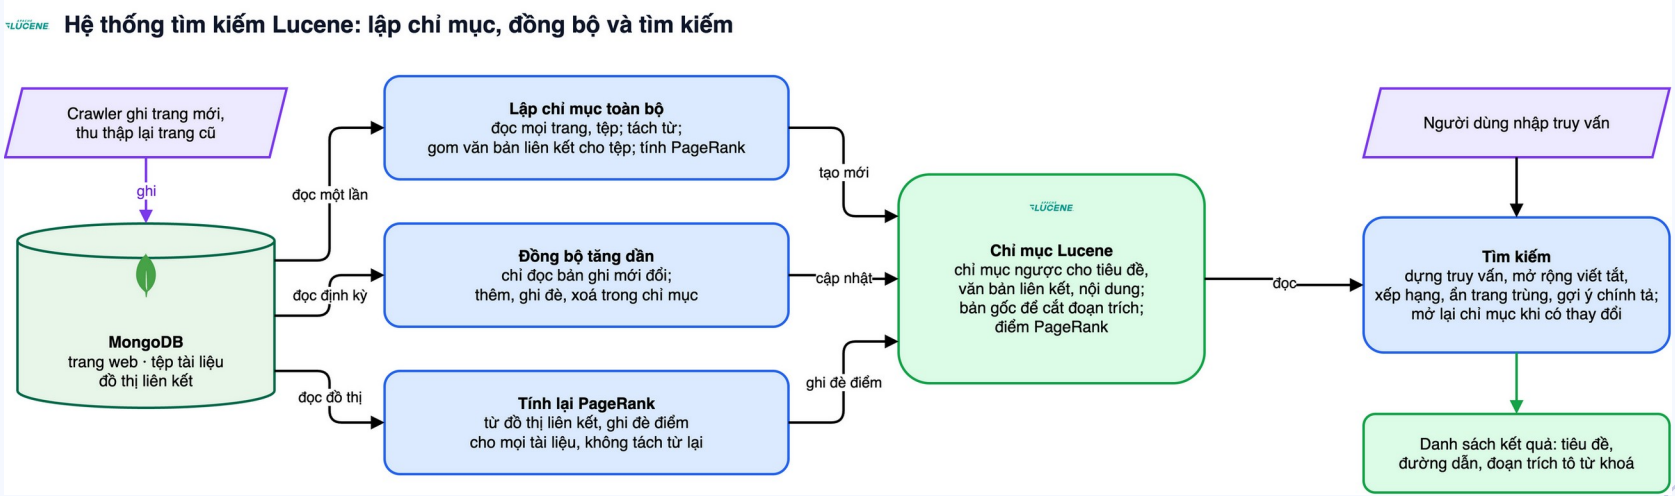


03

Tìm kiếm Lucene

Lập chỉ mục và tìm kiếm trên kho dữ liệu

Kiến trúc tìm kiếm



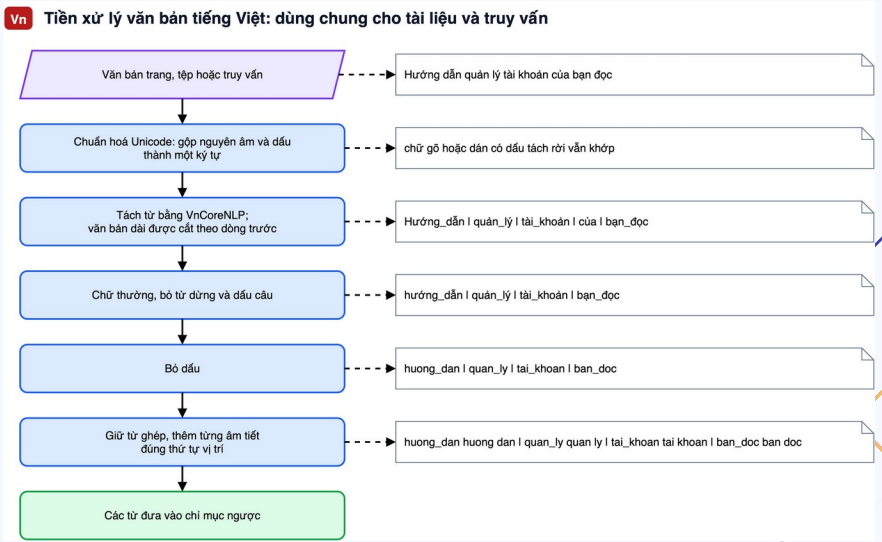
Tiền xử lý văn bản tiếng Việt

Tài liệu và truy vấn đi qua cùng một chuỗi bước.

VnCoreNLP dùng để tách từ; văn bản dài được cắt theo dòng trước khi tách.

Bỏ dấu, nên gõ không dấu vẫn tìm được.

Giữ từ ghép và thêm từng âm tiết đúng vị trí, để khớp theo cụm khi cách tách từ lệch nhau.



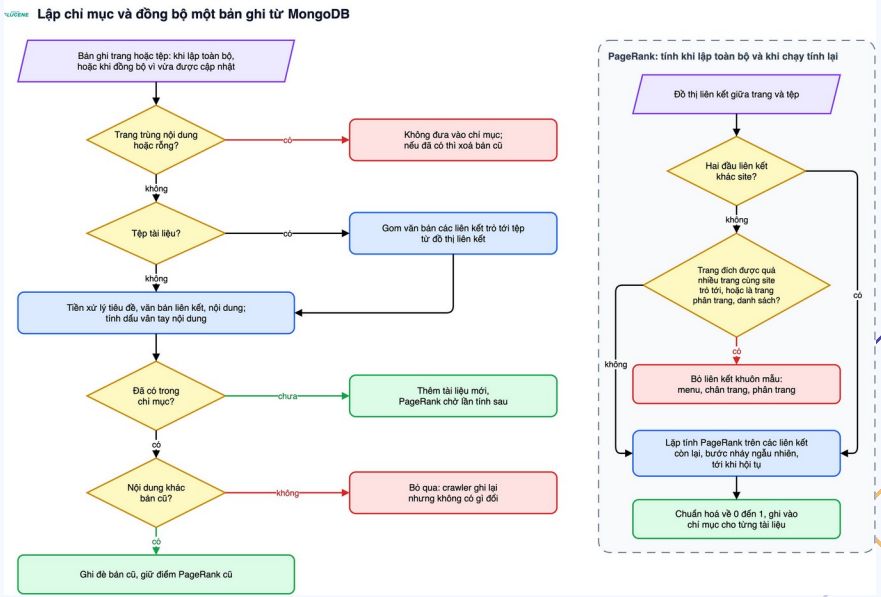
Lập chỉ mục

Mỗi trang, mỗi tệp là một tài liệu, khoá là URL; trang trùng nội dung bị bỏ.

Tệp PDF được gắn văn bản các liên kết trỏ tới nó; ảnh tìm qua tiêu đề, nội dung trang chứa ảnh và tên tệp.

Đồng bộ chỉ đọc bản ghi vừa đổi: thêm, ghi đè hoặc xoá.

PageRank bỏ liên kết khuôn mẫu như menu, chân trang do có rất nhiều url cùng 1 page.



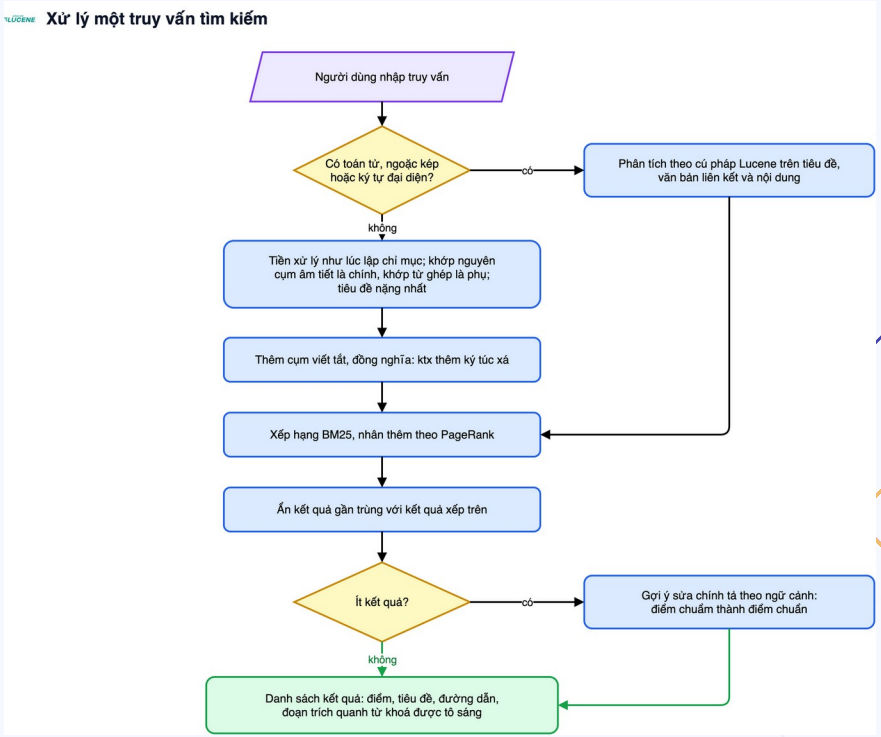
Tìm kiếm và xếp hạng

Truy vấn trơn: tính điểm theo âm tiết đứng liền nhau + từ ghép.

Title có trọng số x3 content, intro có trọng số x1.5 content.

Thêm viết tắt của trường, như ktx thành ký túc xá.

Điểm = BM25 × (1 + 0,5 · PageRank).

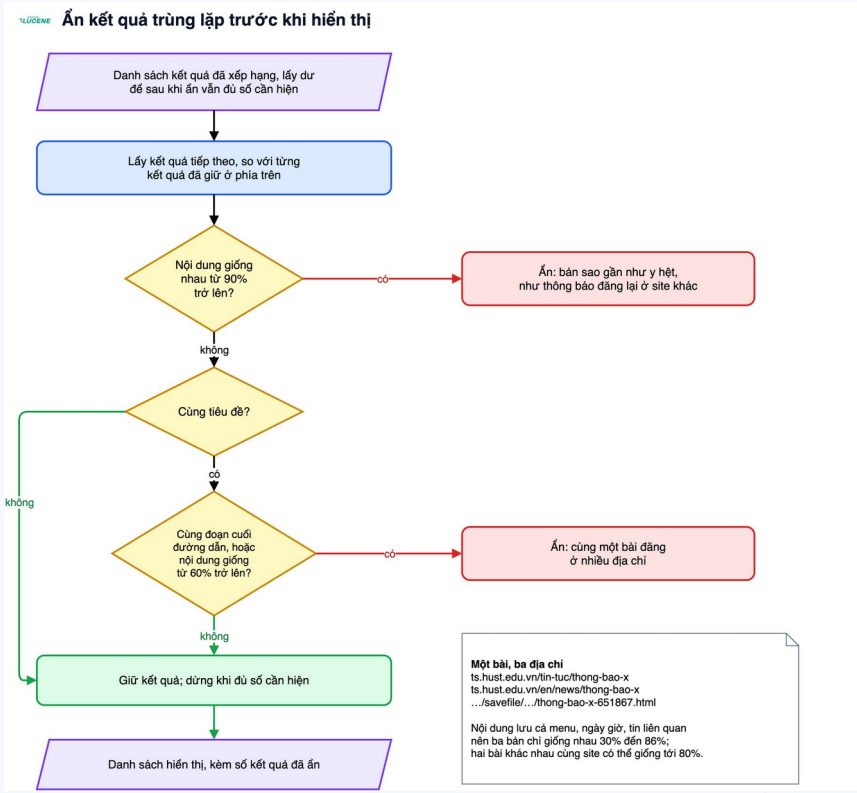


Ẩn kết quả trùng lặp

Một bài thường có nhiều địa chỉ: bản tiếng Việt, bản tiếng Anh, bản in.

Chỉ so nội dung không đủ: ba bản chỉ giống nhau 0,84 và 0,86.

Ẩn khi nội dung giống từ 90%, hoặc cùng tiêu đề và thêm: cùng đường dẫn hay nội dung giống từ 60%.



04

Kết quả

Bộ dữ liệu thu được và kết quả tìm kiếm

141.353 trang

từ 77 website, kèm 5.860 tệp tài liệu

98.274 ảnh

đã tải về từ các trang thu thập

8,25 triệu

liên kết giữa các trang trong đồ thị

Kết quả tìm kiếm

116.132 tài liệu, chỉ mục 398 MB, lập trong 635 giây.

Khoảng 0,13 giây mỗi truy vấn.

Đồng bộ một đợt 161 bản ghi trong 1,1 giây.

Ẩn trùng: bản sao cùng bài trong top 10 của 20 truy vấn từ 29 còn 0.



Cảm ơn!