ĐẠI HỌC BÁCH KHOA HÀ NỘI



BÁO CÁO BÀI TẬP LỚN

THU THẬP, BÓC TÁCH VÀ TÌM KIẾM THÔNG TIN TRÊN CÁC WEBSITE ĐẠI HỌC BÁCH KHOA HÀ NỘI

Học phần IT4863: Tìm kiếm thông tin

Giảng viên hướng dẫn: TS. Nguyễn Bá Ngọc

Nhóm sinh viên thực hiện: Nhóm BAT

STT	Họ và tên	Mã số sinh viên
1	Doãn Văn An	20252778M
2		
3		

Hà Nội, tháng 10 năm 2026

Mục lục

1. Giới thiệu 3

1.1. Đề bài 3

1.2. Phạm vi 3

2. Thu thập và bóc tách dữ liệu 5

2.1. Kiến trúc tổng thể 5

2.2. Điều phối, tải và lập lịch thu thập lại 5

2.3. Bóc tách trang web và tài liệu 6

2.4. Phát hiện thay đổi, loại trùng và lọc liên kết 8

2.5. Lưu trữ, đồ thị liên kết và ảnh 9

2.6. Lược đồ MongoDB và xuất dữ liệu 10

3. Tìm kiếm thông tin với Lucene 12

3.1. Tiền xử lý văn bản tiếng Việt 12

3.2. Lập chỉ mục 12

3.3. Tìm kiếm và xếp hạng 12

4. Kết quả 13

4.1. Kết quả thu thập dữ liệu 13

4.2. Ví dụ bản ghi 13

4.3. Kết quả tìm kiếm 13

Danh mục bảng

Bảng 1. Yêu cầu bóc tách theo đề bài và nơi lưu trong MongoDB 3

Bảng 2. Các mô-đun, cổng và giao diện HTTP 5

Bảng 3. Số lượng bản ghi trong các collection 13

Bảng 4. Tỉ lệ trang web có từng trường bóc tách 13

Danh mục hình

Hình 1. Công nghệ sử dụng theo từng khối 4

Hình 2. Kiến trúc hệ thống thu thập theo mô hình dịch vụ nhỏ 5

Hình 3. Mediator, Downloader và lập lịch thu thập lại 6

Hình 4. Luồng bóc tách của Reader: HTML, PDF, Office, OCR 7

Hình 5. Thuật toán tìm khối nội dung và bóc tách bản ghi trang web 8

Hình 6. Luồng xử lý của Merger 9

Hình 7. Luồng xử lý của Storage và bước tải ảnh 10

Hình 8. Lược đồ MongoDB và quy trình xuất dữ liệu 11

1. Giới thiệu

1.1. Đề bài

Bài tập lớn yêu cầu thu thập dữ liệu từ các website của Đại học Bách khoa Hà Nội, cài đặt thuật toán tìm khối nội dung, bóc tách thông tin, lưu vào MongoDB theo lược đồ tự xây dựng, xuất dữ liệu, rồi dùng kho dữ liệu đó để lập chỉ mục và tìm kiếm. Yêu cầu bóc tách theo từng loại đối tượng ở Bảng 1.

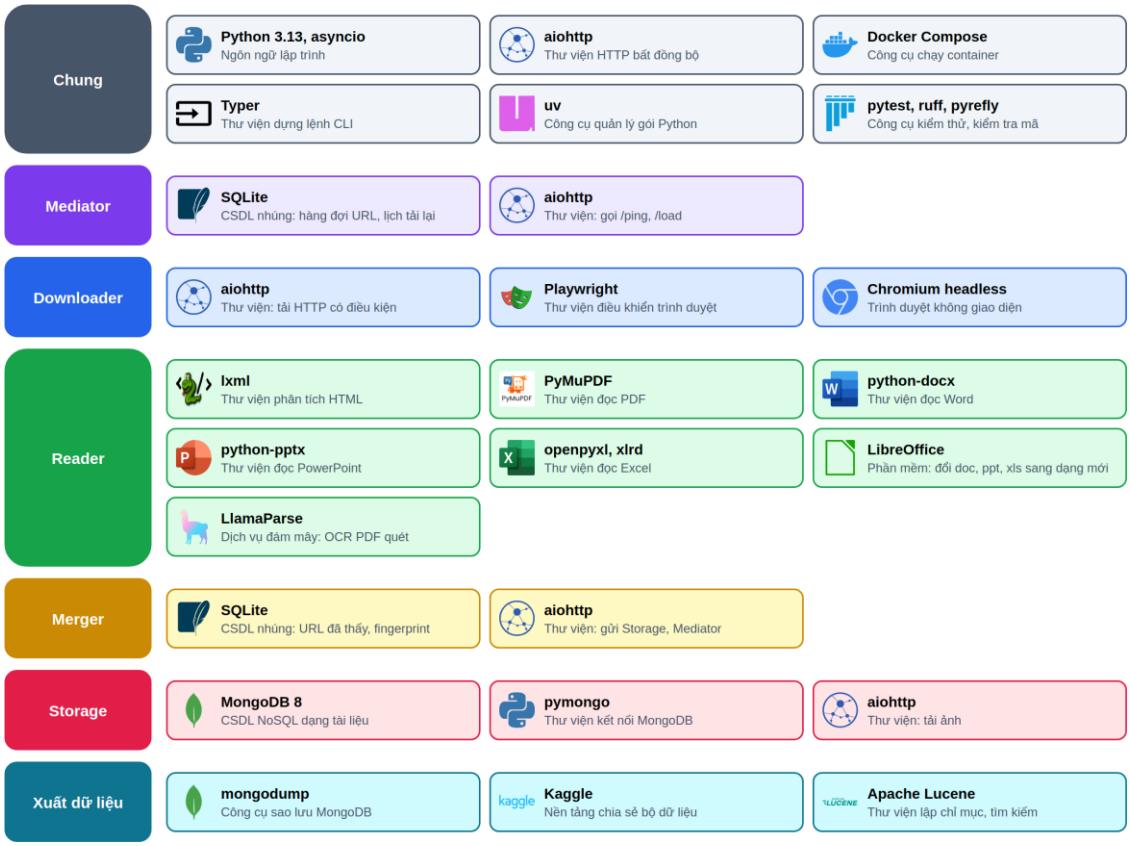
Bảng 1. Yêu cầu bóc tách theo đề bài và nơi lưu trong MongoDB

Đối tượng	Thông tin cần bóc tách	Collection
Trang web	Tiêu đề, ngày đăng, tác giả, nội dung, văn bản liên kết trỏ tới trang	html
Tệp tài liệu	Nội dung văn bản, nguồn giới thiệu	other
Tệp ảnh	Trang chứa ảnh	picture
Đồ thị liên kết	Nguồn → đích : văn bản mô tả	graph

1.2. Phạm vi

Phạm vi thu thập là miền hust.edu.vn: từ 603 hostname, nhóm giữ lại 77 host còn trả nội dung công khai làm URL mầm. Hệ thống theo kiến trúc dịch vụ nhỏ trong slide của giảng viên, viết bằng Python, chạy bằng Docker.

Công nghệ dùng ở từng khối được tổng hợp ở Hình 1, gồm tên, loại (ngôn ngữ, thư viện, công cụ, cơ sở dữ liệu, dịch vụ) và việc nó đảm nhận.

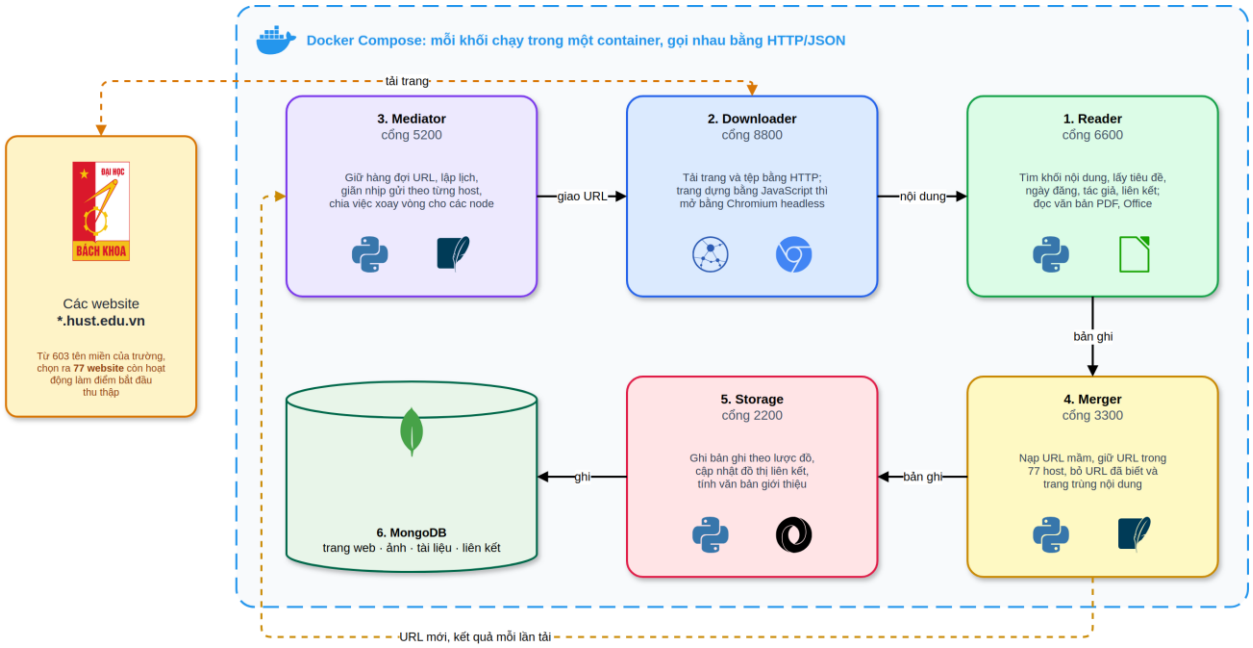


Hình 1. Công nghệ sử dụng theo từng khối

2. Thu thập và bóc tách dữ liệu

2.1. Kiến trúc tổng thể

Hệ thống gồm năm mô-đun cùng MongoDB, mỗi mô-đun một container, giao tiếp bằng HTTP/JSON (Hình 2, Bảng 2). Một URL đi theo vòng Mediator → Downloader → Reader → Merger → Storage; Merger gửi URL mới và kết quả mỗi lần tải về Mediator để thu thập tiếp và đặt lịch thu thập lại.



Hình 2. Kiến trúc hệ thống thu thập theo mô hình dịch vụ nhỏ

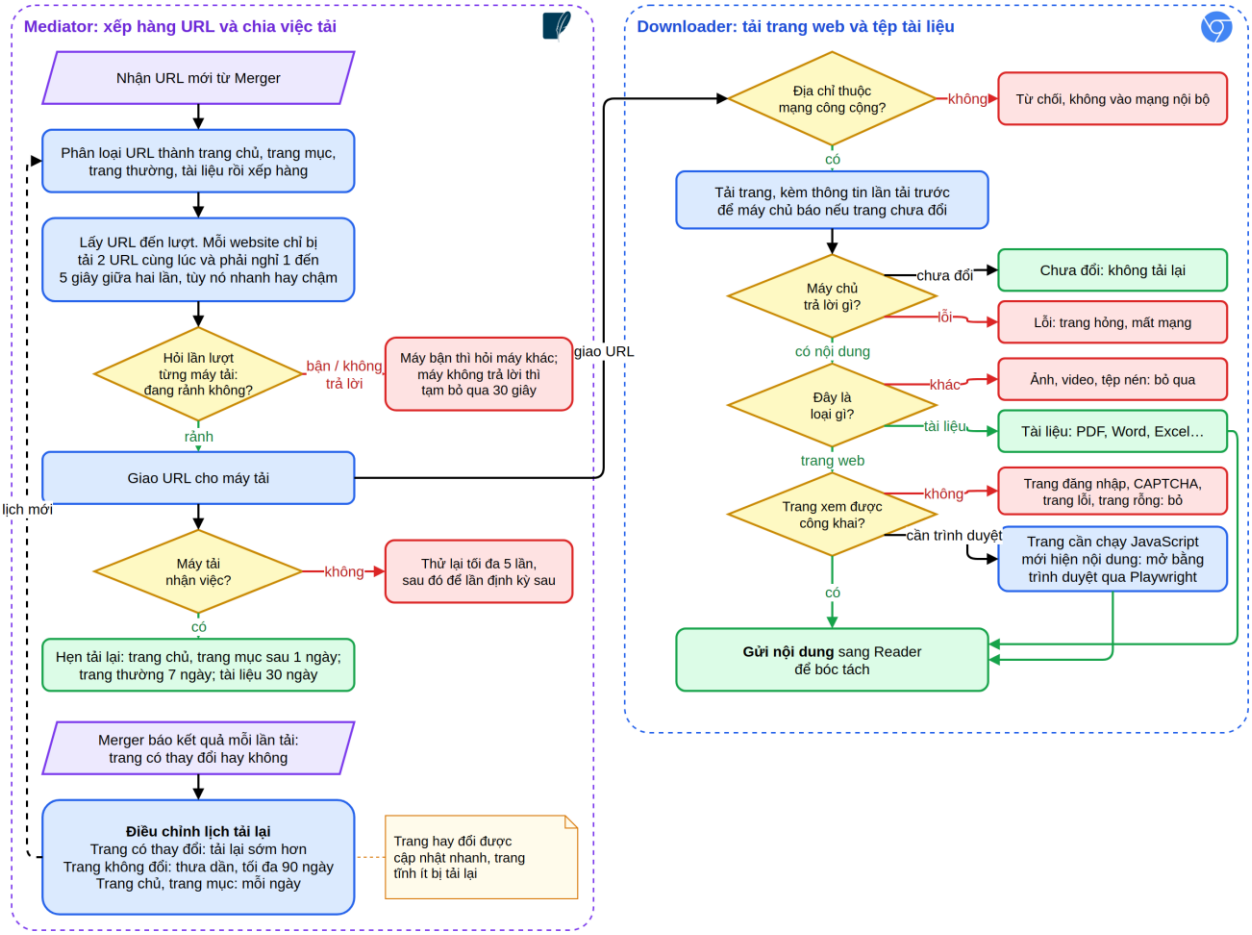
Bảng 2. Các mô-đun, cổng và giao diện HTTP

Mô-đun	Cổng	Endpoint	Việc chính
Reader	6600	POST /parse	Bóc tách trang, tài liệu thành bản ghi
Downloader	8800	POST /load, GET /ping	Tải trang, tệp; mở trang JavaScript bằng Chromium
Mediator	5200	POST /add, /report	Hàng đợi, cân bằng tải, lập lịch thu thập lại
Merger	3300	POST /add	Phát hiện thay đổi, loại trùng, lọc liên kết
Storage	2200	POST /add	Ghi MongoDB, đồ thị liên kết, văn bản giới thiệu

2.2. Điều phối, tải và lập lịch thu thập lại

Mediator chọn URL đến hạn và node Downloader rảnh, giữ nhịp gửi vào từng host để không dồn tải lên website của trường. Downloader không tải lại trang mà máy chủ báo

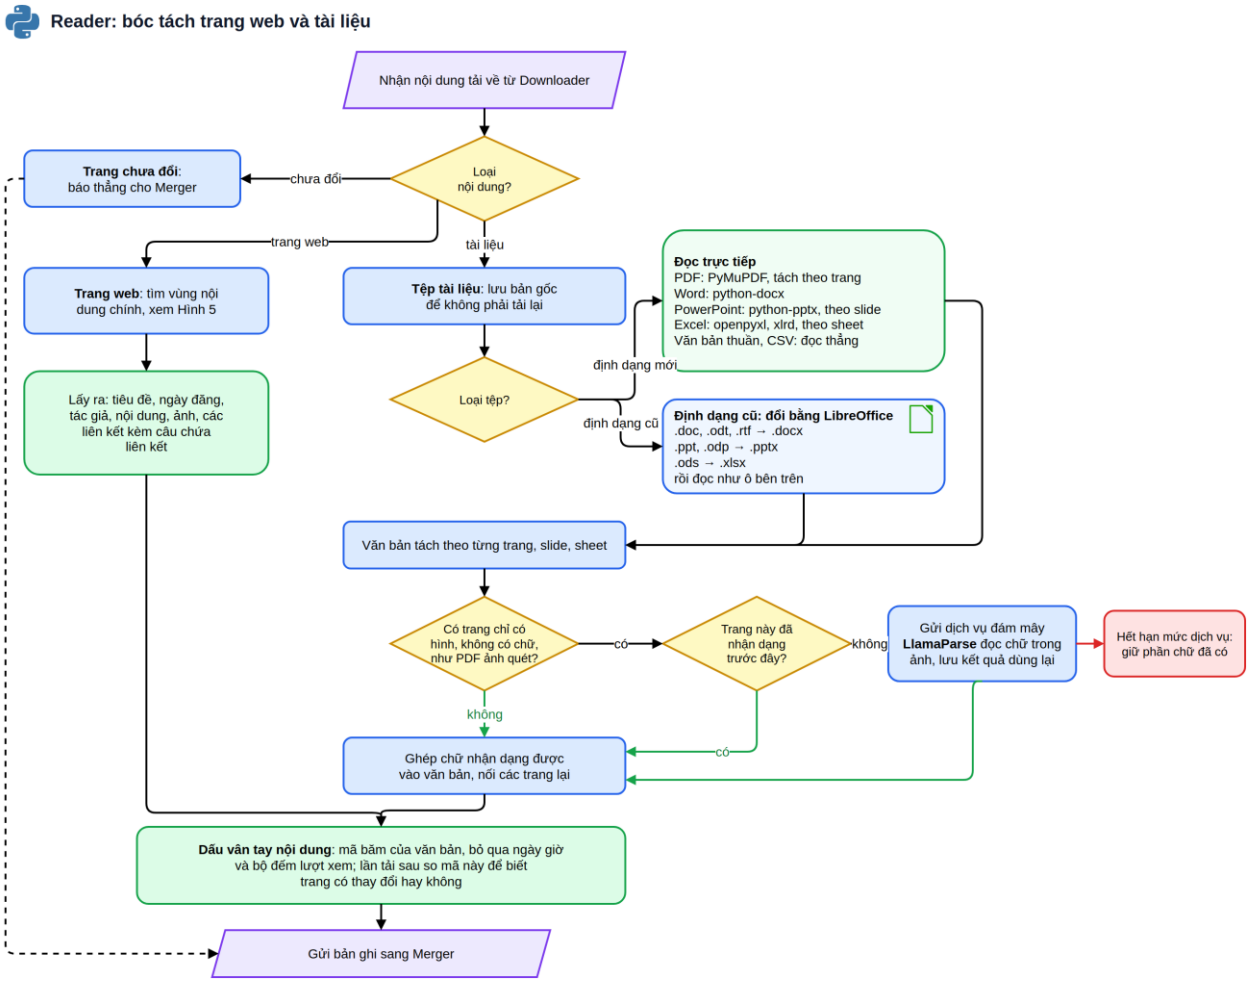
chưa đổi, lọc định dạng và trang không truy cập được. Kết quả mỗi lần tải quay về Mediator để chỉnh lịch thu thập lại (Hình 3).



Hình 3. Mediator, Downloader và lập lịch thu thập lại

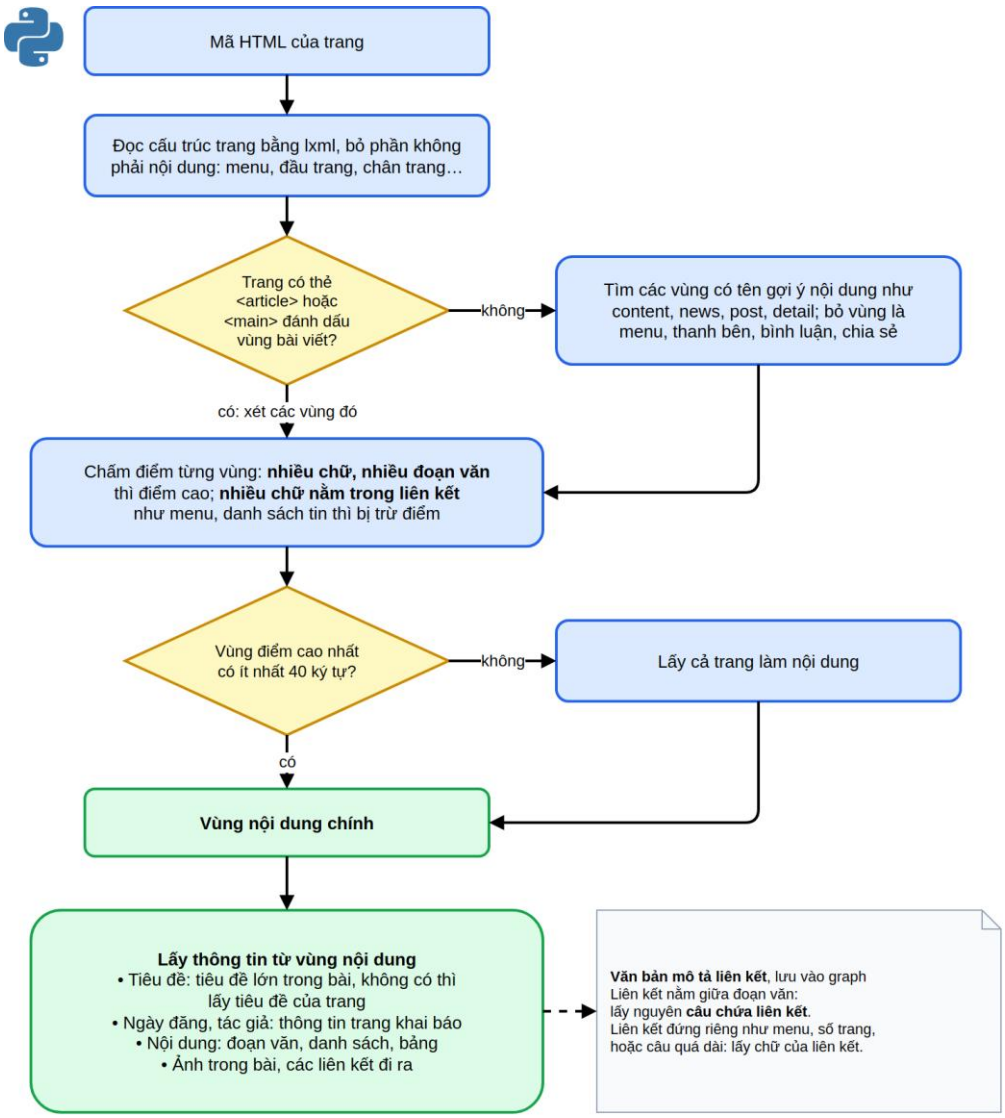
2.3. Bóc tách trang web và tài liệu

Reader phân luồng theo định dạng (Hình 4): trang HTML qua thuật toán tìm khối nội dung; tài liệu Office cũ được LibreOffice đổi định dạng trước khi đọc; trang PDF ảnh quét được nhận dạng chữ bằng LlamaParse. Mỗi bản ghi có một dấu vân tay nội dung để nhận biết trang thay đổi ở lần thu thập sau.



Hình 4. Luồng bóc tách của Reader: HTML, PDF, Office, OCR

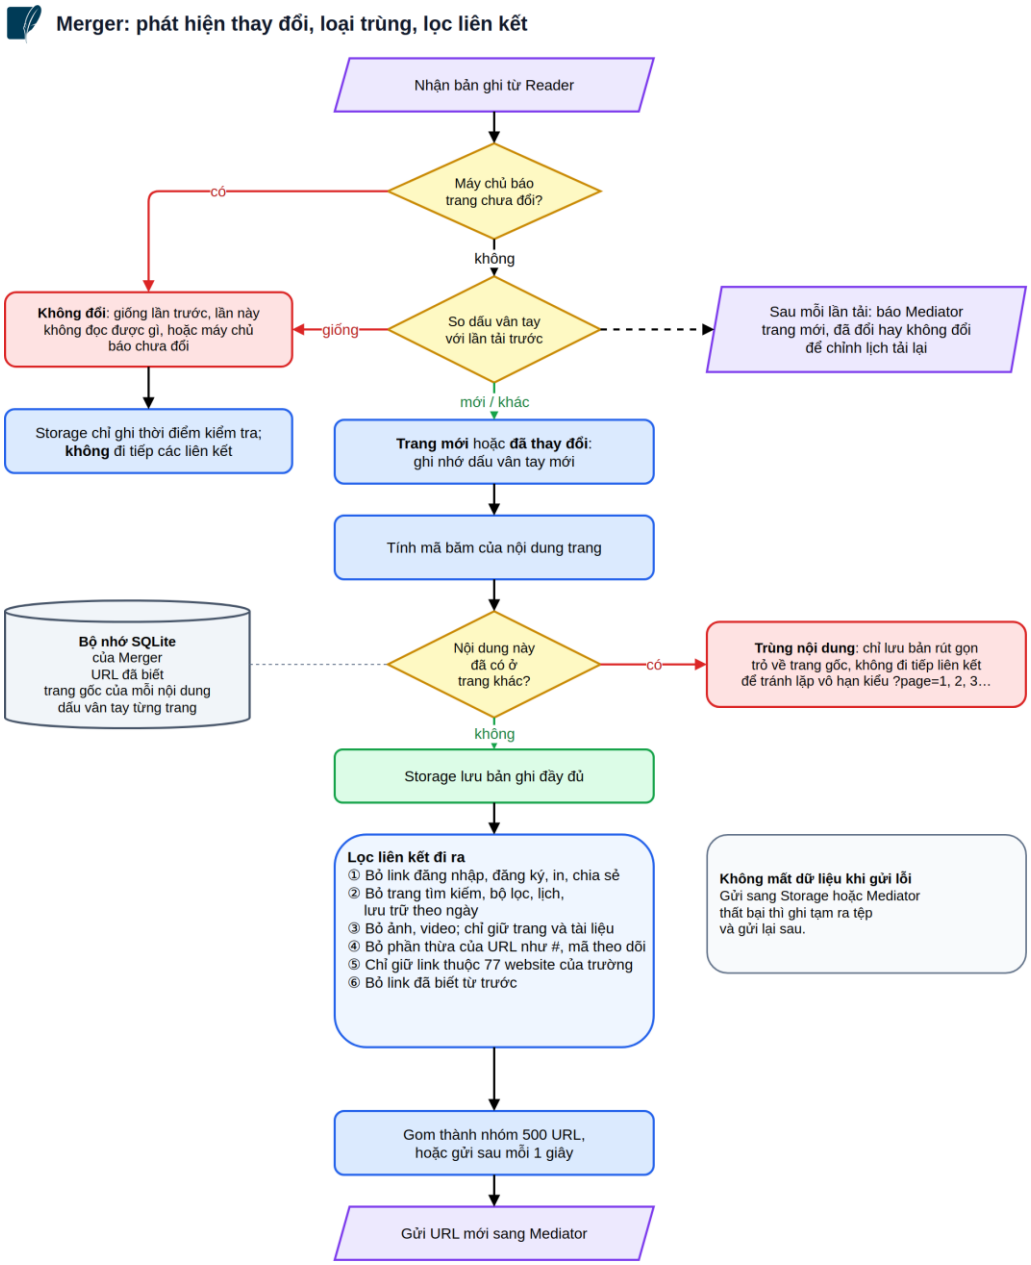
Thuật toán tìm khối nội dung (Hình 5) chấm điểm các phần tử ứng viên theo công thức: điểm = độ dài chữ + 80 × số đoạn <p> − độ dài chữ nằm trong liên kết, rồi chọn phần tử điểm cao nhất. Văn bản liên kết là câu hoàn chỉnh chứa thẻ a, theo đúng slide.



Hình 5. Thuật toán tìm khối nội dung và bóc tách bản ghi trang web

2.4. Phát hiện thay đổi, loại trùng và lọc liên kết

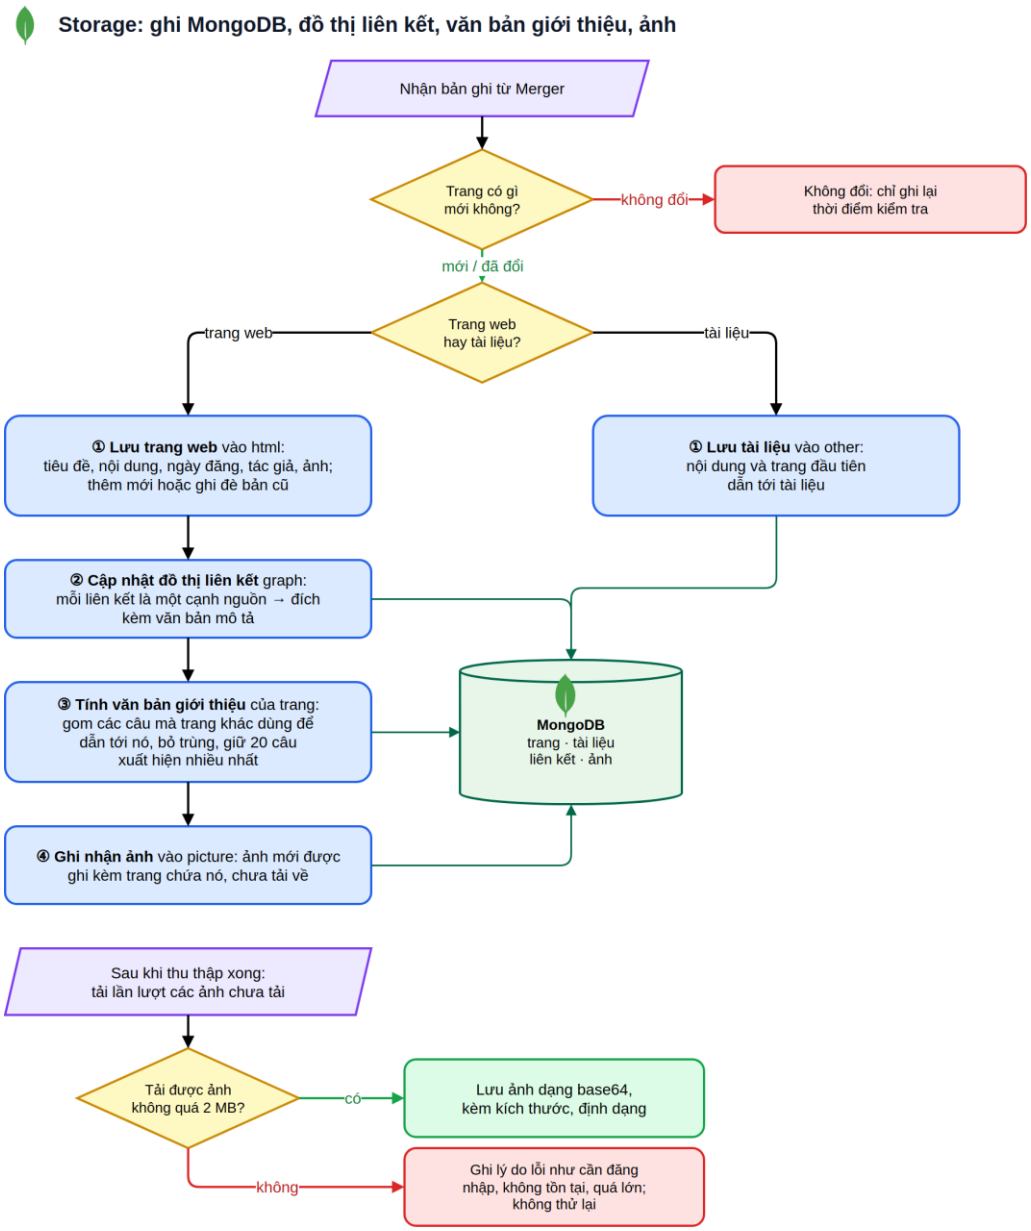
Merger quyết định bản ghi được lưu thế nào và có lan tiếp liên kết hay không (Hình 6). Trang có mã băm SHA-256 trùng với trang đã lưu chỉ được lưu bản rút gọn trỏ về trang gốc; trang không đổi chỉ cập nhật thời điểm kiểm tra; liên kết mới phải qua sáu bước lọc trước khi về mediator.



Hình 6. Luồng xử lý của Merger

2.5. Lưu trữ, đồ thị liên kết và ảnh

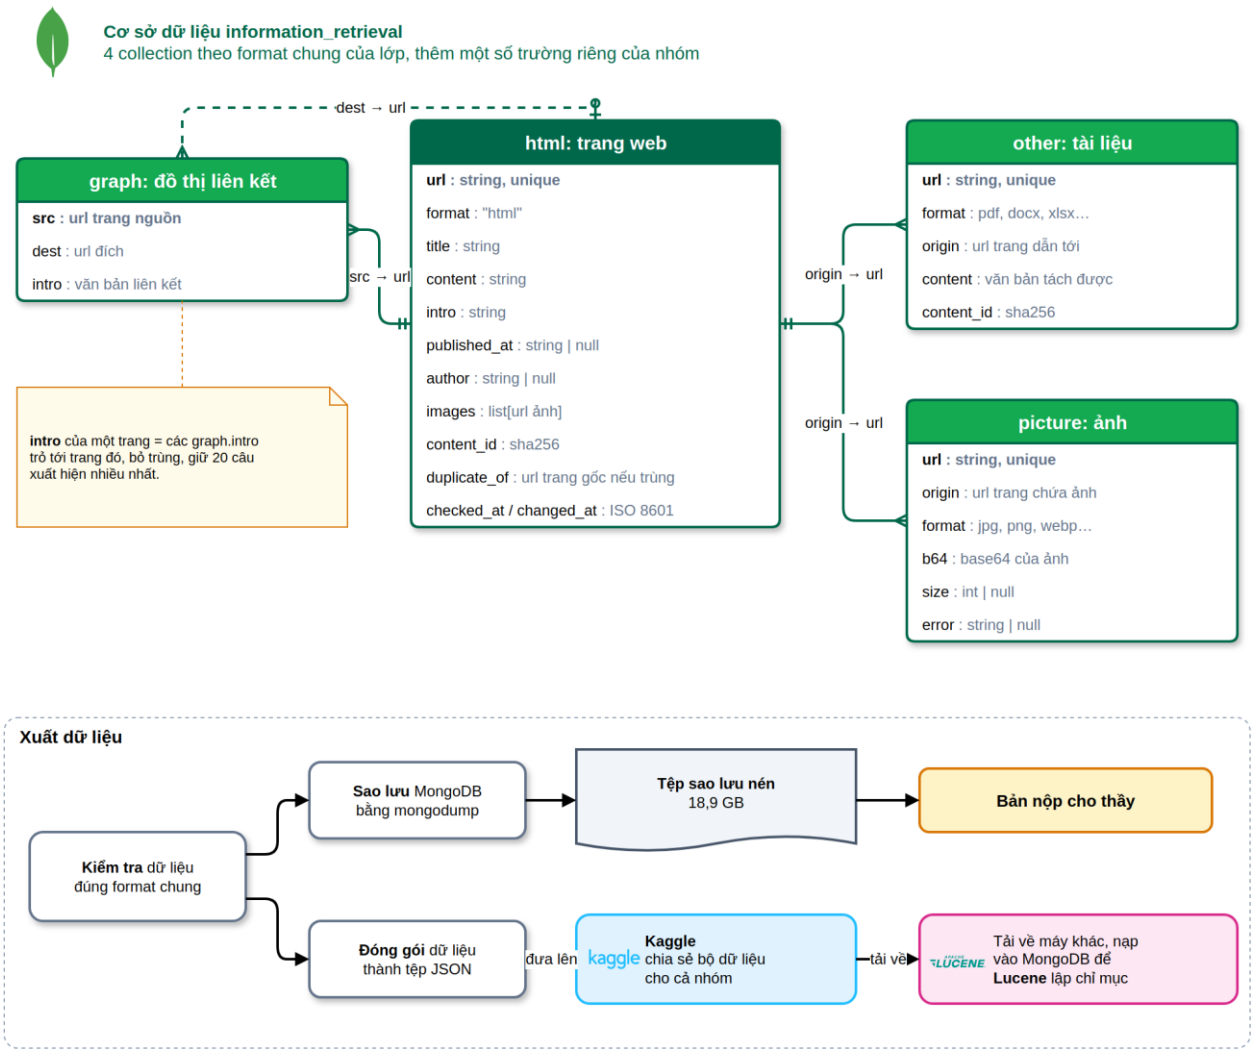
Storage ghi bản ghi vào MongoDB, thay các cạnh của đồ thị liên kết, tính văn bản giới thiệu cho trang và các trang đích, tạo bản ghi ảnh; ảnh được tải sau bằng lệnh crawler pictures fetch (Hình 7).



Hình 7. Luồng xử lý của Storage và bước tải ảnh

2.6. Lược đồ MongoDB và xuất dữ liệu

Bốn collection theo format chung của lớp, cùng một số trường thêm phục vụ loại trùng và thu thập lại (Hình 8). Dữ liệu được kiểm tra rồi xuất thành bản dump để nộp và bộ dữ liệu trên Kaggle để chia sẻ.



Hình 8. Lược đồ MongoDB và quy trình xuất dữ liệu

3. Tìm kiếm thông tin với Lucene

[Phần này do thành viên phụ trách Lucene bổ sung.]

3.1. Tiền xử lý văn bản tiếng Việt

[Nội dung]

3.2. Lập chỉ mục

[Nội dung]

3.3. Tìm kiếm và xếp hạng

[Nội dung]

4. Kết quả

4.1. Kết quả thu thập dữ liệu

Bộ dữ liệu nộp ngày 25/10/2026 gồm trang của 80 host (Bảng 3). Tài liệu chủ yếu là PDF với 5.262 tệp, còn lại là Word, Excel, PowerPoint. 10.434 ảnh không tải được vì dlib.hust.edu.vn yêu cầu đăng nhập.

Bảng 3. Số lượng bản ghi trong các collection

Collection	Số bản ghi	Ghi chú
html	141.353	27.730 trang trùng nội dung chỉ lưu bản rút gọn
other	5.860	pdf 5.262, doc 270, docx 234, xls(x) 82, pptx 12
picture	114.476	98.274 ảnh tải được (85,8%)
graph	8.251.443	Khoảng 58 liên kết mỗi trang

Bảng 4. Tỉ lệ trang web có từng trường bóc tách

Tiêu đề	Văn bản giới thiệu	Tác giả	Ngày đăng
99,1%	87,6%	38,4%	10,2%

Ngày đăng và tác giả thấp vì phần lớn trang là trang giới thiệu, trang mục, trang danh sách, vốn không có hai thông tin này.

4.2. Ví dụ bản ghi


```
{ "url": "https://soict.hust.edu.vn/155-sinh-vien-phan-khoi-...-ky-2024-1.html",
  "format": "html",
  "title": "155 sinh viên phấn khởi trong buổi Lễ Trao chứng nhận Học bổng ...",
  "published_at": "2024-11-22T11:48:01+00:00",
  "author": "Truyền thông SoICT",
  "content": "... Kỳ 1 năm học 2024-2025, Trường Công nghệ Thông tin và ...",
  "intro": "155 sinh viên phấn khởi trong buổi Lễ Trao chứng nhận ..." }
```


4.3. Kết quả tìm kiếm

[Phần này do thành viên phụ trách Lucene bổ sung.]